

中山大学硕士学位论文

复杂网络视角的通信网络通信模式分析和性能优化研究

**Research on the Effect of Communication Patterns and
Optimization of Communication Network with the
Perspective of Complex Network**

学位申请人：曾俊文

指导教师：

专业名称：

答辩委员会主席：

答辩委员会成员：

二零一八年五月

论文原创性声明

本人郑重声明: 所呈交的学位论文, 是本人在导师的指导下, 独立进行研究工作所取得的成果。除文中已经注明引用的内容外, 本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体, 均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名: _____

日期: _____

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定, 即: 学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版, 有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅, 有权将学位论文的内容编入有关数据库进行检索, 可以采用复印、缩印或其他方法保存学位论文。

学位论文作者签名:

日期: 年 月 日

导师签名:

日期: 年 月 日

论文题目： 复杂网络视角的通信网络通信模式分析和性能优化研究

专 业：

硕 士 生： 曾俊文

指导教师：

摘 要

在当今社会，随着技术的不断进步，由计算机构成的通信网络系统成为当今世界最为重要的基础网络。从世界第一台计算机诞生到现在的几十年间，通信网的持续高速发展给我们的工作、生活、学习带来了深刻而又意义深远的革命性影响。现在的通信网已经成为由众多计算机、路由器和其他通信设备经由通信光缆等物理传输介质链接而成的一个典型的复杂网络。在目前的通信系统中，通信拥塞和级联失效不可避免的发生在各种通信网络中。因此，如何缓解拥塞和防止级联失效，提高通信网络的传输性能和鲁棒性成为通信网络研究领域里越来越重要的课题，同时吸引来自物理界和工程学界的广泛关注。

针对以上问题，本文从复杂网络视角研究不同通信模式对不同拓扑结构的通信网络的影响，全面分析网络拓扑、通信模式和资源分配与网络性能之间的关系。我们将在不同拓扑结构的网络中进行不同网络通信模式的设计，通过仿真实验得到网络中的资源分配情况和网络性能指标 (数据的平均传输路径，网络的传输能力，网络的鲁棒性等)，从而梳理清楚各指标之间的关系。其中，考虑的拓扑结构有三种：ER random network、BA scale-free network 和含社区的 BA scale-free network；考虑的通信模式有四种通信模式：选择度最大的节点为主机节点 (HDTA)、选择度最小的节点为主机节点 (LDTA)、选择介数中心性最大的节点为主机节点 (BTA) 和随机选择节点为主机节点 (RA/RTA)。在对通信模式分析完成后，针对优化网络性能问题设计了两种启发式算法对网络进行优化：模拟退火算法和基于集合的粒子群算法，并详细分析了优化后的网络特点。最后，论文结合通信模式分析中的实验结果和优化实验中优化后的网络特点，设计了两种种基于解特征的启发式算法 (F-SA 和 F-S-CLPSO) 对网络进行优化，该算法能够在确保优化结果不变的情况下降低对网络的优化时间。

本文从复杂网络的理论角度完成了对通信网络性能分析到对通信网络优化，

有针对性的提出了基于解特征的启发式优化算法，该算法在理论网络拓扑模型和真实网络拓扑模型上的表现与传统算法相比不仅能够保证优化效果，还能提高优化效率。除此之外，论文中还考虑了复杂通信网络的优化问题，针对该问题，论文中提出了具有一定现实指导意义的基于罚金和集合的综合学习粒子群算法(S-CLPSO-P)。

关键词： 通信网, 复杂网络, 通信模式, 模拟退火算法, 粒子群优化算法

Title: Research on the Effect of Communication Patterns and Optimization
of Communication Network with the Perspective of Complex Network
Major:
Name: Junwen Zeng
Supervisor:

Abstract

In today's society, with the continuous improvement of technology, the communication network system constituted by computer becomes the most important basic network in the world. From the birth of the world's first computer to the present decades, the continuous and rapid development of the communication network has brought about profound and revolutionary influences on our work, life, and study. It has become a typical complex network of computers, routers and other devices linked by physical transmission media, such as cables. In the current communication system, communication congestion and cascading failure are unavoidable in various communication networks. Therefore, how to alleviate congestion and prevent cascading failure, improve the transmission performance and robustness of communication network become more and more important topic in the field of study on the communication network, at the same time attract widespread attention from physics and engineering academic circles.

For above problems, we research the traffic generation patterns and network topology on the impact of communication network performance from the perspective of complex network, comprehensively analyze the relationship between resource allocation and network performance. We conduct simulation experiments on different traffic generation patterns in different topology networks. Network resource allocation and network performance are obtained by simulation experiments. Network performance contains average data transmission path, network transmission capacity, network robustness. Among them, there are three kinds of networks: ER random network, BA scale-free network and BA scale-free network with community structure. For traffic generation pattern, we according to a certain way to place host nodes, such as select high degree

nodes as hosts, low degree nodes as hosts, high betweenness centrality nodes as hosts, random choice nodes as hosts. For optimization problem, we use simulated annealing algorithm and particle swarm algorithm to optimize the network. Finally, based on the conclusion of traffic generation patterns analysis and the network characteristic in optimization experiment, two heuristic algorithms based on solution features (F-SA and F-S-CLPSO) are designed to optimize the network. The algorithm can reduce the optimization time of the network while ensuring the optimization result is invariable.

We complete the process of analyzing the performance of communication network to the optimization of communication network from the theoretical perspective of complex network. Two heuristic algorithms based on solution features are designed to optimize the network. The performance of algorithm compared with the traditional algorithm is not only ensure the optimization effect, also can improve the efficiency of optimization in theoretical network model and real network model. In addition, the dissertation also takes into account the complex communication network optimization problems. For this problem, we design a comprehensive learning PSO based on set and penalty.

Keywords: communication network, complex network, communication pattern, simulated annealing algorithm, particle swarm optimization algorithm

目 录

摘要	I
Abstract	III
第一章 绪论	1
1.1 研究背景和意义	1
1.2 研究现状	2
1.3 论文创新点与主要工作	4
1.4 论文章节安排	4
第二章 复杂网络模型与优化算法	5
2.1 复杂网络基本性质与模型	5
2.2 通信网络性能	11
2.3 模拟退火算法	16
2.4 粒子群优化算法	18
2.5 结束语	25
第三章 通信模式对网络性能的影响	26
3.1 主机节点对通信网络传输能力的影响	27
3.2 主机节点对通信网络鲁棒性的影响	30
3.3 结束语	37
第四章 通信网络性能优化	38
4.1 基于传统启发式算法优化简单通信网络	38
4.2 基于解特征的启发式算法优化简单通信网络	48
4.3 复杂通信网络优化	53
4.4 结束语	60
第五章 总结与展望	62
5.1 总结	62
5.2 展望	63

参考文献	65
攻读学位期间发表的学术论文和研究成果	70

第一章 绪论

本章首先介绍论文的研究背景和意义，然后对通信网和复杂网络的研究现状进行分析，最后总结了论文的主要工作与创新点，并简要概括论文的章节安排。

1.1 研究背景和意义

1.1.1 研究背景

网络由一些相似或相同的个体和他们之间的连边构成，如互联网、万维网、社会关系网、交通网络、生物网络等等。对于网络科学的研究可以追溯到 18 世纪，当时欧拉对“七桥问题”的研究开创了图论和几何拓扑的新数学分支。到 20 世纪 60 年代末，哈佛大学社会心理学家 Stanley Milgram 提出的“六度分离理论”反应出了人际关系网的小世界特性。1998 年，Watts 和 Strogatz 在 Nature 杂志上发表了揭示复杂网络的小世界特性并建立相应模型的文章^[1]。次年，Barabasi 和 Albert 在 Science 发表了揭示复杂网络无标度特性并建立相应的无标度网络模型的文章^[2]。

随着科学技术的发展，计算机和通信网络系统已成为当今世界最为重要的基础网络之一，人类政治、经济、文化的发展从此注入了鲜活动力，从此人类社会已经进入了复杂网络时代。由于人类的生活与生产活动越来越多的依赖各种复杂网络系统安全和有效运行，因此许多国家将复杂网络这个新领域提上了国家科技发展的规划中，在中国复杂网络作为基础研究已被列入《国家中长期科学和技术发展规划纲要 (2006-2022)》。此后网络科学迅速兴起，并受到越来越多的关注。

美国国家研究局（The United States National Research Council）的报告把网络科学定义为“研究物理、生物、以及社会现象的网络表达式，并建立这些现象的预测性模型”^[3]。目前的网络科学既是数学上经典的图论和随机图论的延伸，也是系统科学和复杂性科学的创新发展。网络科学中包括了复杂网络。复杂网络是网络科学发展的重点方向，他作为跨领域的新兴学科主要以研究自然科学

和人文科学中各种复杂系统微观性态和宏观现象之间的联系。例如网络结构形成机理、演化方式、动态行为、结构模式、运动规律、调控策略。复杂网络关注的研究方向主要在网络拓扑性质、网络性能（传输能力和鲁棒性）、交通线路规划、电网设计、病毒传播预防、链路预测、社区发现等。作为一门从交叉学科中成长起来的网络科学，融合了数学、统计物理、计算机科学等，主要致力于研究复杂系统的网络结构性质及其相关动力学行为^[4-6]。

复杂网络的复杂性及研究内容为：

- 1) 结构的复杂性：现实网络结构复杂，包括了成千上万条边不等，如何根据现实数据建立能够模拟现实网络某些特性的理论模型。
- 2) 节点的多样性：在网络中存在着大量不同种类的节点，研究他们之间的动力学原理，改善网络性能。例如设施选址问题^[7, 8]。
- 3) 网络之间的相互影响：现实生活中的网络存在相互依赖的关系，比如电网的瘫痪会导致互联网不能正常工作。

1.1.2 研究意义

今天的人类社会能够迅猛发展得益于各种发达的网络。互联网的发展让我们进入了信息社会，方便了人们的生活。由于网络资源的需求迅速增加使得有限承载数据传播的网络需要传输大量的数据，这时网络节点可能发生阻塞，一个节点的阻塞可能导致其他节点的阻塞甚至发生瘫痪。所以如何保证网络的传输性能和鲁棒性值得我们深入研究。

1.2 研究现状

网络负载传输的可靠性和效益对网络系统而言至关重要，并在过去几十年被广泛研究。David^[9]研究了负载分布变化对网络性能的影响，他假设网络中每个节点产生数据的速率一样，数据的传输采用最短路径规划。David 的实验揭露了负载分配和网络拓扑结构的关系。Pablo 在 2004 年发表一篇关于通过改进路由策略来优化网络性能的论文^[10]。这两篇文章揭示了网络的负载传输能力与网络的拓扑结构和路由算法有很强关系，因此传统方法对网络的优化方式主要分为调整网络的拓扑结构^[11, 12]和设计适合的路由算法^[13, 14]。如 Zhang Guo-qing^[11]

在 2007 年提出的通过删边来提高网络的传输能力, Huangwei^[12] 在 2010 年提出了通过增加节点和连边来优化网络的传输能力, Tanfei^[13] 在 2013 年提出了一种采用混合路由算法方式来优化网络。以上提到的网络性能只与网络的传输能力相关, 除此之外还有很多关于网络鲁棒性的研究。网络的鲁棒性是衡量网络稳定性的一个指标。对网络鲁棒性的研究主要集中在级联失效模型^[15, 16], 级联失效防御策略^[17, 18], 失效种类^[19]。在网络稳定工作时, 不可避免的会由于外界或自身原因导致网络中的节点失效, 这种失效将打破原网络的平衡状态, 这使得网络自身要重新寻找一个新的平衡状态。级联失效模型分为三种: 1、简化模型; 2、概率模型^[20]; 3、积分模型。在简化模型中, 只要节点的负载超过该节点的能力限制, 该节点马上失效, 目前大量关于级联失效的研究集中于该模型中。对于概率模型, 每个时间节点只失效一个节点, 如何判断哪个节点失效? 对于负载超过自身能力的节点是否失效和其负载超过自身传输数据能力的大小成正相关。负载超过自身传输能力越大的节点, 失效概率越大。积分模型相对于前两种模型而言复杂很多, 更能贴合实际。在该模型中考虑了时间因素, 因为节点在发生阻塞乃至失效是有一个过程的, 而且目前对于积分模型的研究甚少。当节点自身负载超过自身传输能力时, 来不及发送的数据会不断在节点的 buffer 中不断积累。当 buffer 满了以后, 该节点会存在丢包现象, 从而不能正常工作。对级联失效的研究, 通常考虑蓄意攻击一个节点和随机攻击一个节点的情况, 如果节点的负载小, 当节点被攻击时只会影响到少部分的节点, 反之影响越多的节点。在文献^[16] 中, 研究表明如果一个网络的负载分布呈现出高度的异质性, 那么当我们攻击最繁忙的节点时将会导致网络发生大规模的级联失效。在早期的工作中^[16, 21–23], 研究表明 Barabási-Albert(BA) 无标度网络^[2] 在随机攻击情况下鲁棒性高, 但在蓄意攻击下网络很脆弱。Erdős-Rényi(ER) 随机网络^[24] 在随机攻击和蓄意攻击情况下鲁棒性都很高。网络的鲁棒性同网络的传输性能一样, 受到网络拓扑结构和网络路由算法的影响, 文献^[17, 25–32] 分别从这两方面进行了研究。除了在单层网络研究外, 最近涌入了部分科研人员对多层网络进行研究, 文献^[33–36] 研究了真实世界中两个网络是如何相互作用的。Tan^[36] 在他的文章中研究了相依网络的鲁棒性和脆弱性, Chen^[34] 研究了电网与通信网络构成的相依网络的级联失效过程。

1.3 论文创新点与主要工作

目前在对复杂网络的大量研究中,对特定网络 (BA scale-free network、ER random network) 的研究主要集中在一个简单的模型:网络中的每一个节点都具有一样的功能,均能产生数据和发送数据。然而在现实的网络系统中的节点通常具有多种特性。最典型的就是在通信系统中主要有两种节点,路由器和主机。其中路由器能接收和转发数据,主机除了拥有路由器的功能外还具有产生数据的功能。与此同时,主机还是网络数据传输的目的地。为了能够更好的模拟真实网络,本论文针对含有路由和主机的 ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络进行研究。在这种网络中,负载的分布不仅与网络的拓扑结构和路由算法有关,还与主机的位置有关。本文研究的通信模式只涉及主机的位置放置方式。

本论文将研究以下几点:

- 1) 通信模式如何影响负载在网络中的分配。
- 2) 通信模式对网络的性能有怎样的影响。
- 3) 基于启发式算法研究性能较好的网络特点。
- 4) 基于粒子群优化算法对复杂通信网络进行优化。

1.4 论文章节安排

论文第二章主要对网络的基本参数和网络模型进行阐述,分析通信网络传输机理和级联失效模型,如何衡量网络传输性能和鲁棒性。对模拟退火算法和粒子群优化算法进行理论阐述,为第四章的优化做铺垫。第三章将在第二章的铺垫下研究四种通信模式对网络传输性能和网络鲁棒性的影响。第四章将详细描述如何用模拟退火和离散化的粒子群优化算法对网络的性能进行优化,并分析优化后的网络具有怎样的特点。基于分析实验和优化实验,提出了两种基于解特征的启发式算法对网络传输性能进行优化。除此之外,在本章的末尾将对复杂通信网络的优化进行了研究。第五章主要为研究总结和展望,针对文章不足之处进行讨论,为下一步研究奠定基础。

第二章 复杂网络模型与优化算法

本章首先在 2.1 节中介绍网络的基本参数和复杂网络领域常用的网络基本模型。2.2 节从通信系统传输机理和通信系统级联失效出发，描述了在考虑网络中有主机和路由的情况下，如何衡量网络传输性能和鲁棒性。2.3 小节对模拟退火算法进行了介绍。2.4 节阐述了几种常用粒子群算法，并从控制理论的角度说明了粒子群优化算法中的各参数如何影响粒子的运动。在该小节最后，列出了粒子群优化算法的两种离散方法。

2.1 复杂网络基本性质与模型

2.1.1 复杂网络基本参数

早在大规模复杂网络科学兴起之前，学术界已经开始传统图论的研究。传统的图论往往着眼于具有某种规则结构或者节点数目较小的图，因而在理论分析时可以采用图示的方法直观的看出图的某些性质。然而，由于近年网络科学研究中涉及的实际网络往往包含了成千上万的节点，而且具有复杂的不规则拓扑结构。本小节将对复杂网络科学中的参数进行描述：

- 度与平均度：度是刻画单个节点属性的最简单而又最重要的概率之一。在无向网络中节点 i 的度 k_i 定义为与节点直接相连的边的数目。网络中所有节点的度的平均值称为网络的平均度，记为 $\langle k \rangle$ 。而对于有向网络中节点的度包括入度 k_i^{in} 和出度 k_i^{out} ，平均度包括平均入度 $\langle k^{in} \rangle$ 和平均出度 $\langle k^{out} \rangle$ 。
- 密度：一个包含 N 个节点的网络的密度定义为网络中实际存在的边数 M 与最大可能边数之比，

$$\rho = \frac{2M}{N(N-1)}, \quad (2-1)$$

- 最短路径与平均路径长度：网络中链接两个节点的边数最少的路径，也称测地距离或跳跃距离。网络的平均路径长度为任意两个节点之间的距离的

平均值,

$$D = \frac{2}{N(N-1)} \sum_{i>j} d_{ij}, \quad (2-2)$$

- 聚类系数: 聚类系数用来刻画一个节点的两个邻居互为邻居的概率。对于网络中一个度为 k_i 的节点 i 的聚类系数定义为,

$$C_i = \frac{2E_i}{k_i(k_i - 1)}, \quad (2-3)$$

除了该定义外, 聚类的数的另一个定义是从几何角度来做的定义,

$$C_i = \frac{\text{包含节点 } i \text{ 的三角形的数目}}{\text{以节点 } i \text{ 为中心的连通三元组的数目}}, \quad (2-4)$$

- 介数中心性: 以经过某个点的最短路径的数目来刻画节点重要性的指标。介数中心性也简称为介数, 节点 i 的介数定义为,

$$BC_i = \sum_{s \neq i \neq t} \frac{n_{st}^i}{g_{st}}, \quad (2-5)$$

其中, g_{st} 为从节点 s 到节点 t 的最短路径的数目, n_{st}^i 为节点 s 到节点 t 的 g_{st} 条最短路径中经过节点 i 的最短路径数目。介数中心性的算法可参考文献^[37]。

- 接近中心性: 接近中心性反应了一个节点到网络其他节点的接近程度,

$$CC_i = \frac{N}{\sum_{j=1}^N d_{ij}}, \quad (2-6)$$

- 同配系数: 用来刻画网络是同配网络还是异配网络, 该系数的计算可以参考文献^[38], 为正时表示同配; 为负时表示异配, 为 0 时表示为中性。

2.1.2 复杂网络基本模型

1999 年, Barabási 等人在研究网络中节点度分布的幂率现象中, 发现在现实网络中大量存在着生长和偏好依附两种机制。基于这两个机制, 他和他的团

队提出了 BA 无标度网络模型，从而解释了网络中存在幂率的起源。但是 BA 无标度模型是一个机制模型，不能用来完整描述互联网、论文引用网络或万维网等。BA 无标度网络模型只是用来解释网络无标度特性背后的机制，在这种机制背后会导致网络呈现出怎样的特性。真实世界的网络的幂指数从 2 到 8 不等，而 BA 无标度网络的幂指数不会超过 3。为了更真实的了解真实网络，Mends、Dorogovtsev、Redner、Krapivsky 等人基于连续理论的速率方程，将发生在真实网络中的许多因素纳入到了无标度模型中。例如节点的消失、旧连接的删除等。这些因素会改变网络的幂指数。除此之外，这些因素使得度分布以可预见的方式偏离单纯的幂率。这些偏离现象包括：

- 小度饱和：网络中已经存在的两个节点可以选择相互连接，度分布形式可写为 $P(k) = C(k + A)^{-\gamma}$ ，就会产生小度饱和^[39]。
- 高度截断：如果偏好依附是非线性的，那么度分布就会遵循拉伸指数，或者具有指数截断的幂率。除此之外，移除节点也会产生高度截断。
- 适应度：在连接中，节点有不同的能力。通过给每一个节点一个独特且不同的适应度 η 。有了适应度之后， $P(k)$ 的精确形式将会是基于适应度的分布 $\rho(\eta)$ 。例如一个均匀的适应度分布将会使 $P(k)$ 有一个 \log 修正。

表 2-1 四种真实通信网络的基本属性。

参数	as-Skitter	as-733	as-Caida	Oregon-1
Nodes	1696415	6474	26475	10670
Edges	11095298	13233	106762	22002
Diameter	25	9	8	10
Average Distance	4.07242	3.705003	3.581519	3.641746
Average Degree	13.080877	4.292555	4.194485	2.062137
Degree Standard Deviation	20.748327	25.08002	78.97331	31.98756
Assortativity	-0.090261	-0.159939	-0.1309585	-0.1863361
α	0.7	1.800343	2	4.876279

我们对斯坦福网络分析项目 (<http://snap.stanford.edu/>) 的真实网络数据进行了研究。为了说明研究的结果，我们挑选了 4 个网络在此进行说明。表2-1展示了四个网络的拓扑结构特性，图2-2展示了四个网络的幂率分布拟合曲

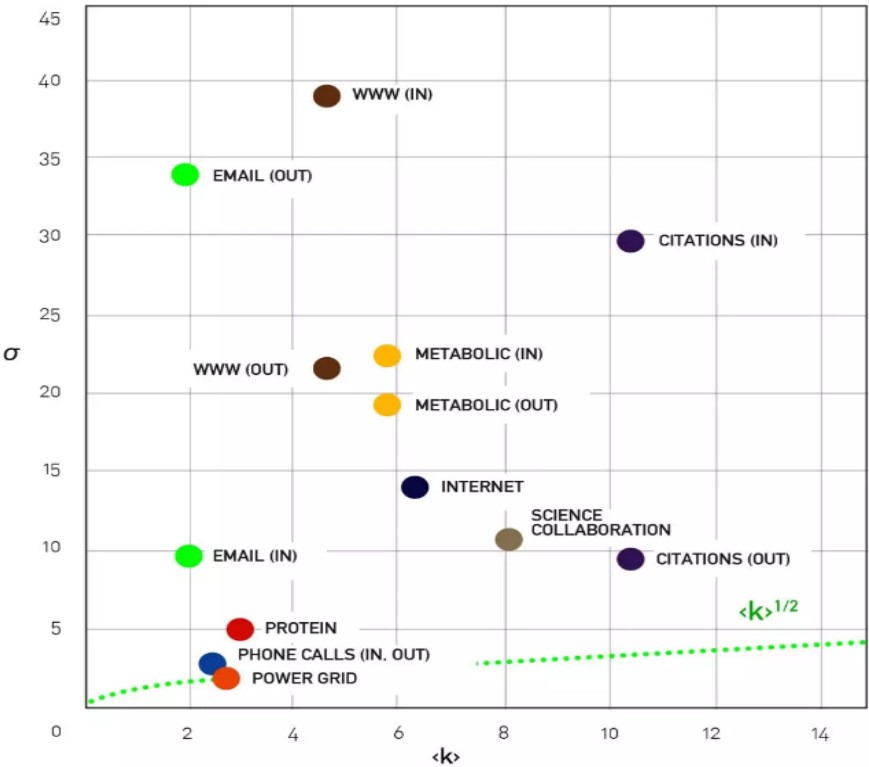


图 2-1 度方差和平均度坐标图。绿色曲线为随机网络在坐标曲线中的度方差与平均度关系曲线。

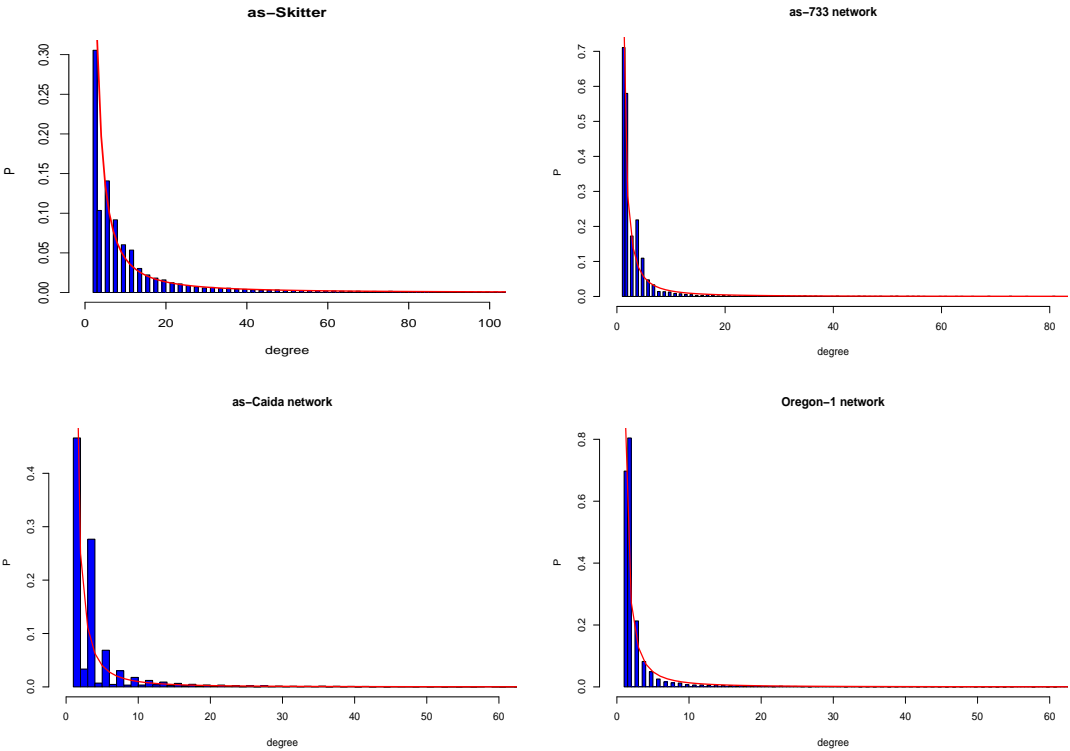


图 2-2 四种真实网络的度分布。

线。从表2-1可以看出不同规模的网络的平均路径是在 3.5 到 4.1 之间，远小于各自网络的直径。说明这四个网络表现出了小世界特性。介数中心性的值均为负数，说明了现实网络的异构性，呈现出了小度节点倾向于与大度节点相连的特性。图2-2展示了四个网络的度分布。红色曲线是采用幂率函数拟合后的曲线，从图可以看出各网络中的度分布呈现出了具有幂率分布的趋势。各网络的幂率指数 α 值如表2-1中所示，这四种网络满足学术界无标度网络的特性，均为无标度网络。四种网络中度分布的幂率现象反映了网络背后的生长模型和依附偏好两种机制。图2-1展示了各种真实网络度的方差与类似大小随机网络度的方差的差异，如果方差值越高，那么无标度模型的有趣特性将在网络中体现出来，无论度是否遵循单纯的幂率。图中绿色曲线为具有泊松分布的随机网络的度数标准差。图中电网和通话网络可以认为不是无标度网络，他们可以被随机网络模拟。除此之外，著作^[4]指出现实中大量的网络的拓扑结构的度分布服从幂律分布。

如果网络不具有依附偏好的属性，例如电网，我们可以用 ER 随机网络来模拟该网络拓扑结构。随机网络模型是 Erdős 和 Rényi 于 20 世纪 50 年代末开始研究的，ER 随机图理论一直是研究复杂网络拓扑的基本理论，其构造算法如下：

对于给定 N 个节点和待添加的边数 M ，随机连边：

- 1) 随机选取一对没有边相连的不同的节点，并在这对节点之间添加一条边。
- 2) 重复步骤 1)，直到 M 对不同的节点对之间各添加了一条边。

1998 年，Watts 和 Strogatz 在《Nature》上发表了一篇与小世界网络模型相关的论文，论文中提到的 WS 小世界模型构建的网络模型具有小世界特性，但是网络的度分布满足的是泊松分布，该分布在度的平均值 $\langle k \rangle$ 处有一个峰值，然后呈指数快速衰减，这种网络称为均匀网络或指数网络。该模型并不能很好的体现现实网络的无标度特性。1999 年 9 月 Barabási 小组在《Nature》上发表了一篇文章，该文揭示了现实网络的幂率分布的普适性。同年 10 月又在期刊《Nature》上发表了建立无标度网络的 BA 网络模型。该模型能够解释现实网络中的生长模型和偏好依附机制，比如大部分的互联网。该 BA 无标度网络模型的构造算法如下：

- 1) 增长：从一个具有 m_0 个节点的连通网络开始，每次引入一个新的节点并且连到 m 个已存在的节点上，这里 $m \leq m_0$ 。

- 2) 优先连接：一个新的节点与一个已经存在的节点 i 相连接的概率 P_i 与节点 i 的度 k_i 之间满足如下关系：

$$P_i = \frac{k_i}{\sum_j k_j}, \quad (2-7)$$

如果一个网络既有偏好依附属性，又有社区结构，论文^[40]提出了如何构建有社区的无标度网络。含有社区的 BA 无标度网络模型的构造算法如下：

假设网络中有 $M(M \geq 2)$ 个社区。

Step 1 : 初始化

在每个初始的社区里含有 $m_0(M_0 > 1)$ 个全连接的节点，用 $\frac{M(M-1)}{2}$ 条社区间连边将所有社区连接起来，从而保证每个社区之间有一条连边相连，社区之间的连边链接的节点从社区中随机选择。

Step 2 : 增长

每一步，随机选择一个节点添加到社区中。新节点链接同一个社团中的 $m(1 \leq m \leq m_0)$ 个节点，以概率 α 连接 $M - 1$ 个社区中的 $n(1 \leq n \leq m)$ 个节点。

Step 3 : 优先连接

- 社区内优先连接：当选新添加节点所在社区的社区内的节点与新加入的点连接时，假设选择选中的概率为 Π ，该概率由节点 i 在社区 j 的 *inner-degree* s_{ij} 决定。 s_{ij} 表示在社区 j 中连接节点 i 的边数。

$$\Pi(s_{ij}) = \frac{s_{ij}}{\sum_k s_{kj}}, \quad (2-8)$$

- 社区间优先连接：当选区新添加节点所在社区外的其他社区的节点与其连接时，假设选取的概率为 Π ，该概率由节点 i 所在社区 $k(k \neq j)$ 的 *inter-degree* l_{ik} 决定。 l_{ik} 表示在社区 k 中连接节点 i 的边数。

$$\Pi(l_{ik}) = \frac{l_{ik}}{\sum_{m,n,n \neq j} l_{mn}}, \quad (2-9)$$

生成含社区的 BA 网络的伪代码为算法2.1。

算法 2.1 The algorithm of evolving network model with community structure

```

1: procedure POWER-LAW NETWORK WITH COMMUNITY
2:    $M \leftarrow$  the number of communities
3:    $m_0 \leftarrow$  the number of nodes in each community
4:    $V_{num} \leftarrow$  the number of nodes you want to add
5:    $m \leftarrow$  the number of inner-community links you want to add when add a new node
6:    $n \leftarrow$  the number of inter-community links you want to add when add a new node
7:    $\alpha \leftarrow$  connection probability
8:   for each community do
9:     each node be fully connected;
10:  end for
11:  for each community do
12:    random choicing a node connects to other each commuinties;
13:  end for
14:  for each adding node addingNode do
15:    community=Belong_To_Witch_Community();
16:    for  $i=0; i++; i < m$  do
17:      choicingNode=Choice_Node_From_Community(community);
18:      Connect_Node(addingNode,choicingNode);
19:    end for
20:    for  $i=0; i++; i < n$  do
21:      choicingNode=Choice_Node_From_Other_Community(community);
22:      Connect_Node_With_Probability( $\alpha$ ,addingNode,choicingNode);
23:    end for
24:  end for
25: end procedure
26:
27: procedure (Choice_Node_From_Community(community))
28:   choice a node from community community with the probility which is proportional to
29:   its inner-degree;
30: end procedure
31:
32: procedure (Choice_Node_From_Other_Community(community))
33:   choice a node from community expect community with the probility which is
34:   proportional to its inter-degree;
35: end procedure

```

2.2 通信网络性能

在该小节，本文将详细描述通信网络传输机理及网络的级联失效模型。

2.2.1 通信系统传输机理分析

在通信系统的网络模型中，本文考虑一种典型的负载模型。在该模型中，每一个数据或信息通过包的呈现方式在网络中进行传输。到目前为止的很多研究中，认为模型中的每个节点都具有生成数据和转发数据的功能。为了详细的模拟现实网络，在我们的模型中将节点分为类：主机 (host) 和路由 (router)。需要传输的数据包只能在主机上生成，然后以一个时间单位一跳的方式向目的主机传递，直到数据到达目的主机后，数据将从网络中释放掉，同时路由器只有接收转发数据的功能。

- 数据包生成：在每一个时间单位，随机选择一个主机节点产生新数据包并随机选择一个主机作为需要发送到的对象 (这两个主机不能是同一个)。如果每个主机在单位时间内产生的数据包数量为 λ ，在整个网络中主机的数量为 N_{host} ，那么在网络中单位时间产生的数据量为 λN_{host} 。
- 数据包传输：在每一个时间单位，网络中的节点将会接收到邻居节点发送过来的数据并将数据存储在自己的缓存队列中。每一个队列满足先入先出的规则 (first-in-first-out)，新产生和刚接收到的数据包将被放在队列的末尾。当数据包到达各自的目标主机时，数据包从网络中释放掉。

在不规则的异质性网络中，节点有着不同的度和迥异的重要性。在实验中，我们发现度大的节点会以较大的可能性被选为数据包传递过程中的中继节点，因此也有着更高的通信负荷。在早期的研究中，研究人员常使用节点介数的概念来估计节点的交通负荷。节点介数定义为网络中所有最短路径中经过该节点的路径数目占最短路径总数的比例。由于在考虑网络结构、网络通信模式和路由策略这三大设计因素时，吴嘉婧老师提出的节点使用概率^[41]能更准确的估算通信网络中节点的交通负荷，所以在本文将采用节点使用概率或节点使用次数来估算通信网络中节点的负荷大小。

节点 i 的节点使用概率 $U(i)$ 的计算式为：

$$U(i) = \frac{\sum_{\substack{u, w \in V_{host}, \\ u \neq w \neq i}} \sigma_{uw}(i)}{\sum_{j \in V} \sum_{\substack{u, w \in V_{host}, \\ u \neq w \neq j}} \sigma_{uw}(j)}, \quad (2-10)$$

算式中 V_{host} 是网络中所有主机节点的集合, V 是网络中所有节点的集合。如果在特定的路由算法下节点 u 与节点 w 之间的路径经过节点 i , 则 $\sigma_{uw}(i) = 1$ 。反之, 则 $\sigma_{uw}(i) = 0$ 。

2.2.2 通信系统级联失效模型

级联失效最初是在 90 年代后期由荷兰 IT 专业人士提出的, 并逐渐成为这种大规模失效的一个比较常见的术语。随着通信网络负载的爆炸式增长和各种通信网之间的紧密链接, 级联失效的发生对网络的影响变得越来越值得关注。当网络中的硬件、软件损坏或失效时, 网络中很大一部分流量将受到很大影响, 通过该失效节点的流量需要重新规划路径, 重新规划的路径可能会导致其他节点失效, 即发生了级联失效。下面对单一节点失效导致的级联失效过程进行描述:

Step 1: 当随机攻击或蓄意攻击时, 从网络中移除被攻击的点。

Step 2: 基于特定的路由算法 (在本文采用最短路径算法) 计算网络中的各个节点使用次数。将节点使用次数作为衡量节点网络负载的指标, 如果节点的负载超过节点能容纳的最大负载, 那该节点将失效并将其从网络中移除。

Step 3: 重复 step2, 直到网络中不再出现节点失效的情况;。

Step 4: 随着网络的的节点不断的失效, 网络将被分成不相连的若干个子网络。

网络受到攻击的两种方式:

- 蓄意攻击 (Intentional attack): 攻击网络中度最高的点或者是最繁忙的节点。
- 随机失效 (Random failure): 随机从网络中选择一个节点进行移除。

2.2.3 通信网络性能指标

1) 传输性能

在早期的相关研究工作中, 研究表明在通信网络中, 随着网络负荷的增大, 存在一个从自由流态至拥塞态的相变点。网络的通信负荷一般以每个时间单位平均每个节点产生的数据包数目 λ 来表示。为了保证通信网络的可靠而又高效的传输, 我们通常需要确保通信网络始终工作在自由状态。通常, 网络由自由态转变为拥塞态的临界数据包生产率 λ_c (critical generation rate) 被视为网络的传输能力指标。当 $\lambda < \lambda_c$ 时, 在每个时间单位, 网络中

新产生的数据包和移除的数据包数目基本相同，网络处于一个自由流稳态。当 $\lambda > \lambda_c$ 时，数据包将随时间增长而在网络中不断积累直至发生数据包丢弃的现象，此时网络进入拥塞状态。由于 λ_c 可以用来衡量网络传输数据的能力，下面本文将对 λ_c 进行推导。

对于每个节点的使用次数定义为：

$$C(i) = \sum_{\substack{u, w \in V_{\text{host}}, \\ u \neq w \neq i}} \sigma_{uw}(i), \quad (2-11)$$

基于 $C(i)$ 计算节点的使用概率：

$$U(i) = \frac{C(i)}{\sum_{j \in V} C(j)}, \quad (2-12)$$

假设每个节点单位时间需要发送的数据量为 λ ，接收数据的主机随机选取。基于平均场理论有，节点 i 的待发送数据量为：

$$\lambda N_{\text{host}} \tilde{D}_{\text{host}} U(i), \quad (2-13)$$

如果节点 i 转发数据量的能力 $R(i)$ 大于或等于待转发的数据量，那该节点就不会发生阻塞而导致数据包丢失。为了让整个网络能够正常的通信，每个节点必须满足以上条件，所以有：

$$\lambda_c = \min_{i \in V} \frac{R(i)}{N_{\text{host}} \tilde{D}_{\text{host}} U(i)}, \quad (2-14)$$

网络中所有节点的使用次数为 $(N_{\text{host}} - 1)N_{\text{host}} \tilde{D}$ ，对于节点 i 有：

$$C(i) = (N_{\text{host}} - 1)N_{\text{host}} \tilde{D} U(i), \quad (2-15)$$

故，

$$\lambda_c = \min_{i \in V} \frac{R(i)}{C(i)} (N_{\text{host}} - 1) = (N_{\text{host}} - 1) * \min \frac{R}{C}, \quad (2-16)$$

从等式3-2可以看出，越大的 $\min \frac{R}{C}$ ，就有越大的 λ_c ，网络的传输性能就越

好, $\min \frac{R}{C}$ 可以作为间接衡量网络传输数据能力的参数。

2) 鲁棒性

鲁棒二字具有健壮和强壮的意思, 系统的鲁棒性的高低是衡量系统在异常和危险情况下系统生存的关键。对于给定的一个网络, 每次从网络中移走一个节点, 也就同时移走了与该点相连的所有边, 从而有可能使得网络中其他节点之间的一些路径中断。如果在两个节点之间有多条路径, 中断其中的一些路径就可能会使这两个节点之间的距离增大, 从而整个网络的平均路径长度也会增大。在复杂网络中, 常用最大连通子图的相对大小和平均路径长度来度量网络的鲁棒性。在随机攻击的情况下, 也有很多文献采用非关键节点的比例来度量网络的鲁棒性。下文将详细描述本文中鲁棒性指标的计算方式。

网络鲁棒性是衡量网络抵御节点攻击和失效的一种能力, 网络鲁棒性的定义必须符合网络的应用场景, 根据具体情况进行定义。在文献^[42]中, 网络的鲁棒性定义为在网络遭受攻击, 发生级联失效后, 最大连通子图 (LCS) 的相对大小,

$$G(i) = \frac{N'(i)}{N}, \quad (2-17)$$

在公式中, N 表示最初时网络中节点的个数, $N'(i)$ 表示网络中移除节点 i , 网络发生级联失效后, 最大连通子网络中剩余的节点数。然而在含有主机 (host) 和路由 (router) 的网络中, 只有主机能作为数据的产生和数据的最终使用节点, 路由只具有转发数据的作用, 因此我们更关心的是网络中主机, 因此本文重新定义了一个新的参数, 即主机存活率,

$$S(i) = \frac{N'_{host}(i)}{N_{host}}, \quad (2-18)$$

在公式中, N_{host} 表示最初网络中主机的个数, N'_{host} 表示网络中移除节点 i , 网络发生级联失效后, 连通子图中还有的最大主机数。在蓄意攻击的情况下, 本文采用移除负载最大的节点, 也就是最繁忙的节点 i 时的 $S(i)$ 来衡量网络被蓄意攻击时的鲁棒性, 记作 S_{attack} 。对于网络中节点随机失效的情况下, 取 $S(i)$ 的平均值来计算随机失效时网络的鲁棒性, 记作 $S_{failure}$, 计

算公式为:

$$S_{failure} = \frac{1}{N} \sum_{n=1}^N S(i), \quad (2-19)$$

除此之外, 本文还采用了重要节点的数量 (the number of critical nodes, NCN) 来衡量网络容忍错误的能力, 在这里将 NCN 定义为那些被移除后会导致网络发生大规模严重失效的节点的数量,

$$NCN(threshold) = \sum_{i \in V} \delta(i), \quad (2-20)$$

$$\delta(i) = \begin{cases} 1; & S(i) < threshold \\ 0; & otherwise. \end{cases} \quad (2-21)$$

其中 V 是最初网络的节点集合。越大的 NCN 意味着网络拥有更多的节点失效会导致网络发生大规模的失效, 也就是说越大的 NCN 意味着在随机失效的情况下网络越脆弱。

网络中节点 i 和节点 j 之间的传输效益定义为节点 i 和节点 j 之间距离的倒数, 如果没有路径从节点 i 到 j , $d_{ij} = +\infty$ 则 $\varepsilon_{ij} = 0$ 。因此, 网络的全局效益定义为:

$$E = \frac{1}{N_{host}(N_{host} - 1)} \sum_{i \neq j \in V_{host}} \frac{1}{d_{ij}}. \quad (2-22)$$

2.3 模拟退火算法

Kirkpatrick 提出的模拟退火又称做模拟冷却法 (Simulated Annealing, SA), 于 1983 年在他的论文^[43] 中提出。该算法是全局组合优化问题的概率局部搜索方法, 允许逐步收敛到近似最优解。它包含了从当前解到更好解的一系列步骤, 根据过渡规则, 偶尔接受一些比当前解更差的解, 以保证域探索的多样性, 并避免陷入局部最优解, 这个过程由一个控制迭代次数的静态或动态冷却时间表来管理。在目前为止的研究中, 针对多组合和连续优化, 出现了多种模拟退火算法的变体, 以保证算法能渐近收敛到全局最优的结果。模拟退火算法由于编写简单、

调参少而被用在多个科研领域。

- 优化目标 F : F 越大越好, 为了防止陷入局部最优解, 方案如下,

$$\Delta c = F(S_{old}) - F(S_{new}); \quad (2-23)$$

当 $\Delta c > 0, U < e^{-\frac{\Delta c}{t}}$ 时, 接受 F 比较差的解。其中 U 是区间 $(0, 1)$ 的随机数, t 是冷却参数, t 越大表示越容易接受更差的解。

- 模拟退火算法: 算法伪代码2.2

算法 2.2 algorithm of simulated annealing

```

1: step1:
2:  $k = 1$ 
3: Select an initial schedule  $S_1$  using some heuristic and set  $S_{best} = S_1$ 
4: Select an initial temperature  $t_0 > 0$ 
5: Select a temperature reduction function  $\alpha(t)$ 
6:  $n \leftarrow$  the number of inter-community links you want to add when add a new node
7:  $\alpha \leftarrow$  connection probability
8: step2:
9: select  $S_c \in N(S_k)$ 
10: if  $F(S_{best}) > F(S_c)$  then
11:   if  $F(S_c) > F(S_k)$  then
12:      $S_{k+1} = S_c$ 
13:   else
14:     generate a random uniform number  $U_k$ 
15:     if  $U_k < e^{-\frac{F(S_k) - F(S_c)}{t}}$  then
16:        $S_{k+1} = S_c$ 
17:     else
18:        $S_{k+1} = S_k$ 
19:     end if
20:   end if
21: else
22:    $S_{best} = S_c$ 
23:    $S_{k+1} = S_c$ 
24: end if
25: step3:
26:  $t_k = \alpha(t)$ 
27:  $k = k + 1$ 
28: if stopping condition = true then
29:   STOP
30: else
31:   go to Step 2
32: end if

```

在算法参数设定中, 初始温度 t_0 越高越好, 但是初始温度的盲目过高会导致算法的收敛时间变长。如果初始温度 t_0 的设定使得解的接收率在 40% ~ 60% 时, 通常能够得到好的实验结果。在每一次迭代中, 温度的下降有两种设定方式可选, (1) $t = \alpha t$; (2) $t = \frac{t}{1+\beta t}$ 。

- 贪心算法: 如果模拟退火算法中的起始温度 t_0 非常低, 那具有全局最优解搜索功能的模拟算法将退化为只具有局部最优解搜索功能的贪心算法。在搜索解的过程中只会接受更好的解。

2.4 粒子群优化算法

Kennedy 和 Eberhart 在 1995 年的论文^[44]中提出的一种基于种群的连续优化随机算法, 粒子群优化 (Particle swarm optimization, PSO)。PSO 的灵感来源于鸟群和鱼群的社会互动行为。在解决问题中, 为了寻找最优解, 每个粒子个体, 根据自己的位移经验和其他粒子的位移经验来不断地更新自身的速度和当前位置。到目前为止, PSO^[45-48]已经成为解决连续优化问题最流行的优化技术之一。在早期提出的 PSO 主要用于连续空间中寻找解决方案, 实验发现 PSO 算法简单, 而且得到的结果令人满意, 所以到现在有很多研究拓展了 PSO 来解决离散空间的组合优化问题。

目前学术界的粒子群优化算法有混合粒子群优化算法 (Hybrid PSO, HPSO)^[49]、协同粒子群优化算法 (Cooperative PSO, CPSO)^[48]、免疫粒子群算法 (Immune PSO, IPSO)^[50]、综合学习粒子群算法 (Comprehensive learning PSO, CLPSO)^[51], 以及用集合方法进行离散的各类粒子群优化算法。混合 PSO 算法在对每个个体的适应度进行计算后将适应度进行排序, 然后将群体中一半适应度差的个体的速度和位置替换为另一半好的, 这样做有助于搜索集合的减小。协同粒子群优化算法的思想是将整个粒子群分为 K 个相互独立的粒子群, 并将这 K 个粒子群分别在 D 维的搜索空间中的 K 个维度上进行可行解的搜索。CPSO 相比基本的 PSO 算法更易跳出局部极值点, 能达到更好的结果, 但是收敛慢。免疫粒子群优化算法是将免疫系统的免疫机制引入到基本的粒子群优化算法中, 具有比较强的全局搜索能力, 从而避免了基本粒子群优化算法容易陷入局部极值点的缺点, 除此之外还缩短了算法的优化时间。综合学习粒子群优

化算法^[51]采用了一种创新的学习策略,利用所有粒子历史最好的信息来更新粒子的速度,这种方法有利于保护粒子的多样性,但是抑制了粒子的收敛速度。文献^[52]提出了一种基于集合的粒子群优化方法来对离散问题进行优化。

2.4.1 几种常用粒子群算法

1) 原始 PSO

在原始 PSO^[44]算法中, M 个粒子相互合作在 N 维空间搜索全局最优解,每个粒子对应两个 N 维变量,位置 $X_i(x_i^1, x_i^2, \dots, x_i^n)$ 和速度 $V_i(v_i^1, v_i^2, \dots, v_i^n)$,在每一次迭代中,每个粒子根据自身的搜索经验和整个粒子群的搜索经验来更新自身的速度和位置,

$$v_i^j = v_i^j + c_1 r_1^j (pbest_i^j - x_i^j) + c_2 r_2^j (gbest^j - x_i^j) \quad (2-24)$$

$$x_i^j = x_i^j + v_i^j \quad (2-25)$$

其中 $PBest_i(pbest_i^1, pbest_i^2, \dots, pbest_i^n)$ 是第 i 个粒子当前最好的解, $GBest_i(gbest^1, gbest^2, \dots, gbest^n)$ 是整个粒子群到目前为止搜索到的全局最好的解, c_1 和 c_2 代表粒子自我启发和社会影响的权重, r_1^j 和 r_2^j 是区间 $[0,1]$ 中的随机数, $j(j = 1, 2, \dots, n)$ 代表第 j 维度。

2) 原始 PSO 的变体

Shi 和 Eberhart 提出了带有惯性权重 w 的速度更新, 作者认为大惯性权重有利于全局搜索, 小惯性权重有利于局部搜索

$$v_i^j = wv_i^j + c_1 r_1^j (pbest_i^j - x_i^j) + c_2 r_2^j (gbest^j - x_i^j) \quad (2-26)$$

Kennedy 和 Mendes^[53, 54] 建议用附近邻居的局部最好位置 $LBest_i$ 来更新速度,

$$v_i^j = wv_i^j + c_1 r_1^j (pbest_i^j - x_i^j) + c_2 r_2^j (lbest_i^j - x_i^j) \quad (2-27)$$

3) 典型原始 PSO 的变体

许多研究通过修改原始 PSO 的学习策略^[51] 和结合其他搜索技术^[55] 来研究新的 PSO 变体。其中最有代表性的是 Liang 等人提出的 CLPSO，其速度更新公式如下，

$$v_i^j = wv_i^j + cr^j(pbest_{f_i(j)}^j - x_i^j) \quad (2-28)$$

其中 r^j 是区间 $[0,1]$ 的随机数， $pbest_{f_i(j)}$ 是粒子 $f_i(j)$ 最好位置的第 j 维值。 $f_i(j)$ 的确定流程如下。随机数 ran 从区间 $[0,1]$ 随机生成，如果 ran 比参数 Pc_i 大， $f_i(j) = i$ 。否则，采用锦标赛法则从随机选择的两个粒子中确定，具有较好适应度的粒子作为 $f_i(j)$ 。该方法使得 $pbest_{f_i(j)}$ 能够学习任何粒子的最好的位置。实验证明^[51]CLPSO 面对复杂多模态函数优化问题表现优秀。其中 Pc 中的 Pc_i 常设为：

$$Pc_i = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1} - 1}}{e(10) - 1} \quad (2-29)$$

2.4.2 粒子群运动轨迹分析

本小节借助现代控制理论的知识来讨论粒子群的收敛特性，通过分析，有助于对粒子群算法中参数值的设定，而不是简单的通过实验验证来确定算法中的参数设置。在控制系统中，收敛是指系统从不稳定达到稳定的过程。设粒子群在 t 代时的最优位置为 $GBest(t)$ ， $GBest^*$ 为粒子群需要搜索的最终位置，粒子群算法收敛公式为，

$$\lim_{t \rightarrow \infty} GBest(t) = GBest^* \quad (2-30)$$

如果在算法执行中在有限的时间内 $GBest$ 不再变化，说明算法已经收敛，此时的 $GBest$ 为局部最优解或全局最优解。在 PSO 算法中公式2-26、2-27可改写为如下状态空间表达式，

$$v_{ij}^{k+1} = wv_{ij}^k + c_1r_1^j(pbest_{ij}^k - x_{ij}^k) + c_2r_2^j(gbest_j^k - x_{ij}^k) \quad (2-31)$$

$$x_{ij}^{k+1} = x_{ij}^k + v_{ij}^{k+1} \quad (2-32)$$

其中 i 表示第 i 个粒子, j 表示第 j 个维度, k 表示第 k 次迭代。为了方便分析, 在变量空间维度为 1, 粒子数目为 1, 在一定迭代范围内粒子的最好位置不变 (为 p 和 g) 的情况下, 粒子的状态转移空间表达式为,

$$X^{k+1} = AX^k + B \quad (2-33)$$

其中

$$X^k = \begin{bmatrix} v^k \\ x^k \end{bmatrix} \quad (2-34)$$

$$A = \begin{bmatrix} w & -(c_1 r_1 + c_2 r_2) \\ w & 1 - c_1 r_1 - c_2 r_2 \end{bmatrix} \quad (2-35)$$

$$B = \begin{bmatrix} c_1 r_1 p + c_2 r_2 g \\ c_1 r_1 p + c_2 r_2 g \end{bmatrix} \quad (2-36)$$

根据 A 有系统的特征方多项式为,

$$|\lambda I - A| \quad (2-37)$$

$$\lambda^2 + (\Phi - w - 1)\lambda + w \quad (2-38)$$

其中 $\Phi = c_1 r_1 + c_2 r_2$, $\Phi \in (0, 4)$, 记 $\Delta = (\Phi - 1)^2 - 2w(\Phi + 1) + w^2$, 则多项式的特征根为,

$$\lambda_{1,2} = \begin{cases} \alpha + \beta \\ \alpha - \beta \end{cases} \quad (2-39)$$

其中 $\alpha = \frac{1}{2}(w + 1 - \Phi)$, $\beta = \frac{1}{2}\sqrt{\Delta}$, 在离散定常线性系统中, 系统稳定的条件是:

1、系统特征根实部为负; 2、特征根的模小于 1。系统平衡状态如表2-2所示。

1) $\Delta < 0$ 时, 特征多项式2.4.2的两根为共轭复数, $\|\lambda_1\| = \|\lambda_2\| = \sqrt{w} \in (0, 1)$, 粒子的运动轨迹是收敛在稳定的焦点。

2) $\Delta > 0$ 时, 根据公式2-39有:

表 2-2

平衡状态类型	A 的特征值
稳定结点	模小于 1 的负实数
稳定焦点	模小于 1, 存在实部的共轭复数
不稳定结点	正实数
不稳定焦点	实部为正的共轭复数
鞍点	不同符号实数
中心	模小于 1 的共轭纯虚数

- 当 $\Phi > 2(w + 1)$ 时, $\max(\|\lambda_1\|, \|\lambda_2\|) > 1$, 粒子运动轨迹不收敛;
- 当 $\Phi < 2(w + 1)$ 时, $\max(\|\lambda_1\|, \|\lambda_2\|) < 1$, 粒子运动轨迹迅速收敛。

由于 $\Phi \in (0, 4)$ 为均匀分布的随机数, 粒子运动在两种状态之间随机切换, 这导致粒子在收敛和不收敛中达到一种平衡。从分析可以看出, 如果我们在迭代的过程中逐渐减小 w 的值, 粒子群在前期的运动轨迹可以迅速收敛, 达到缩小搜索空间的作用, 而在迭代后期, 较小的 w 值能够抑制粒子群轨迹的收敛, 从而使得粒子群能够在不错的搜索空间中找出更好的解。

2.4.3 粒子群优化算法离散化

由于标准粒子群优化算法只适用于解决连续优化问题, 于是 Kennedy 和 Eberhart 在提出标准粒子群算法两年后, 又提出了解决组合问题的粒子群算法^[56]。在该离散化的粒子群优化算法中, 粒子的每个维度只能取到 0 和 1。对于速度公式与标准粒子群优化算法保持一致, 粒子的位置根据速度信息做离散化处理, 这样做的目的是使连续的速度映射到 0 和 1 两个位置。映射公式为:

$$S(v_i^k) = \text{Sigmoid}(v_i^k) = \frac{1}{\exp(-v_i^k) + 1} \quad (2-40)$$

粒子的位置改变规则遵循如下公式:

$$x_i^k = \begin{cases} 1, & \text{if } \text{rand}() < S(v_i^k) \\ 0, & \text{else} \end{cases} \quad (2-41)$$

陈伟能教授在 2010 年发表了一篇针对如何使用粒子群优化算法解决离散优化问题的论文^[52]，论文采用了基于集合的粒子群优化方式 (A Novel Set-Based PSO, S-PSO)。S-PSO 具有以下特点。首先，它基于一种基于集合的表示方案，使 S-PSO 能够表征组合最优化问题的离散空间。第二，候选的解和速度被定义为一个明确的集合，和一个带有概率的集合。在离散的情况下，连续 PSO 算法速度更新和位置更新的数值计算方式将被集合的运算方式所取代。在阐述算法之前，我们将组合优化问题定义为三元组 $(PS, f, \Omega,)$ ，其中 PS 为候选解的集合， f 为目标优化函数， Ω 为条件集合。问题的目标是找到一个全局优化的可行解 $X^* \in PS$ ，满足 Ω 和优化目标函数 f 。问题 $(PS, f, \Omega,)$ 包含了以下特征：

- 1) 空间集合 E 可以分为 n 维， $E = E^1 \cup E^2 \cup \dots \cup E^n$ 。
- 2) 候选解 $X \in PS \in E$ ， $X = X^1 \cup X^2 \cup \dots \cup X^n$ 。
- 3) 如果候选解 X 满足限制条件 Ω ，那 X 就为一个可行解。
- 4) 问题的目标就是找到一个可行解来优化评估函数 f 。

旅行商问题和背包问题是优化组合中的经典问题。在论文^[52]中为了对离散的粒子群算法进行描述，作者结合这两个问题进行了详细的算法描述。

2.4.4 S-PSO 中算法运算规则

下面将对 S-PSO 中算法运算规则进行简单描述，具体细节可以参考作者原文。

- 1) 位置：定义第 i 个粒子的位置是 $X_i \in E$ ，共有 n 维，在算法开始时，每个粒子的位置在解空间中随机选择。在面对特殊情况时，可以根据具体情况来采取特殊手段初始化每个粒子的位置。
- 2) 速度：在 S-PSO 中，速度为位置和概率构成的二元组的集合。粒子 i 的速度定义为 $V_i = \{(e, p(e)) | e \in E\}$ 。通常初始速度的初始化为，从空间集合 E 中随机选取 n 个元素，并分别给他们赋予一个 $(0,1]$ 的概率值，没有选中的那些位置的概率为 0。初始化速度的准则是，初始速度不能够影响粒子的搜索行为和算法的表现。当然，如果能是使得算法结果更好的方法，那就另当别论了。

3) 系数与速度的乘积：对于给定的系数 $c(c \geq 0)$ 和速度 $V = \{(e, p(e)) | e \in E\}$,

$$cV = \{(e, p'(e)) | e \in E\},$$

$$p' = \begin{cases} 1, & \text{如果 } c \times p(e) > 1 \\ c \times p(e), & \text{其他} \end{cases} \quad (2-42)$$

4) 位置 – 位置：对于集合 A, B ,

$$A - B = \{e | e \in A, e \notin B\} \quad (2-43)$$

$A - B$ 遵循传统的集合运算，即剔除集合 A 中在集合 B 中含有的元素。通常集合 A 为粒子群中较优的解，我们希望每个粒子能从 A 中学习到自身没有的“特性”。

5) 系数与位置的乘积：系数与位置的乘积能够使位置信息转换为速度信息，从而能够进行粒子的速度更新。

$$cE' = \{(e, p'(e)) | e \in E\},$$

$$p'(e) = \begin{cases} 1, & e \in E' \text{ 且 } c > 1 \\ c, & e \in E' \text{ 且 } 0 \leq c \leq 1 \end{cases} \quad (2-44)$$

6) 速度 + 速度：对于两个速度 $V_1 = \{(e, p_1(e)) | e \in E\}, V_2 = \{(e, p_2(e)) | e \in E\}$,

$$V_1 + V_2 = \{(e, \max(p_1(e), p_2(e))) | e \in E\} \quad (2-45)$$

在进行位置更新的时候，有可能出现更新后的解不满足要求。为了解决这个问题，我们将从上一次位置信息进行获取信息，若还不能获取到足够的位置信息，那就将获取范围扩大到解空间 E 。

2.5 结束语

本章开始描述了网络的基本参数，接着通过实证分析，描述了三种网络模型：ER Random Network、BA scale-free Network 和有社区的 BA scale-free Network，并分析了他们适合的场景。在网络性能方面，2.2 节推导了衡量网络传输性能的参数 λ_c 和网络的鲁棒性参数 S_{attack} 和 $S_{failure}$ ，为后续章节做好理论铺垫。为了对网络性能进行优化，本章对模拟退火算法和粒子群优化算法进行了介绍。由于在标准 PSO 中的惯性权重和加速度系数在 S-PSO 中扮演了相同的角色，所以标准 PSO 中的参数配置方式也适用于 S-PSO 算法。针对连续的粒子群优化算法，论文从控制理论的角度分析了各个参数对粒子群运动轨迹的影响，从而帮助我们在实验中进行调优。对于离散的粒子群优化算法，在文中介绍了两种离散方法：1、基于连续的速度信息，通过离散函数映射到离散的位置；2、基于集合运算实现粒子群优化算法的离散化。本章 2.4 小节为第四章的优化实验做了理论铺垫。

第三章 通信模式对网络性能的影响

该章解将在不同的网络中研究不同通信模式对网络性能的影响。主要分为传输性能影响和鲁棒性影响两部分。为了评估通信模式对网络传输性能的影响，我们将在 100 个网络中进行实验，网络类型有三种：ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络。三种网络的结构如图3-1所示。网络的基本属性如表3-1所示。

表 3-1 ER 随机网络，BA 无标度网络和 Comm-BA 网络基本信息。表中每个数值均为 100 个网络的平均值

参数	ER	BA	Comm-BA
Nodes	500	500	500
Edges	1988	1988	2100
Diameter	6	6	6
Average Distance	3.238854	2.905003	3.0375607
Average Degree	7.952	7.952	8.4
Assortativity	0.0104173	-0.15136177	-0.1459218




图 3-1 三种网络拓扑结构图，从左往右分别为 ER 随机网络、BA 网络和含社区的 BA 网络。

在实验中我们考虑了四种通信模式：

- 1) HDTA：选择度大的节点作为主机节点。
- 2) LDTA：选择度小的节点作为主机节点。
- 3) BTA：选择介数中心性大的节点作为主机节点。

4) RTA: 随机选择节点作为主机节点。

除此之外, 我们还考虑了不同数目主机对网络的影响。

3.1 主机节点对通信网络传输能力的影响

在该小节, 我们将在 ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络中进行实验, 得出四种模式 HDTA、LDTA、BTA 和 RA 对网络传输性能的影响。实验指标有 C_{max} 、 U_{max} 、主机到主机的平均最短距离和 λ_c 。为了避免随机因素的干扰, 每个参数均为 100 个网络测量值的平均数。在实验中, 假设每个节点的传输能力统一为 $R(i) = 100$ 。从第二章可知:

$$C(i) = (N_{host} - 1)N_{host}\tilde{D}U(i), \quad (3-1)$$

$$\lambda_c = (N_{host} - 1) * \min \frac{R}{C}, \quad (3-2)$$

3.1.1 ER 随机网络

从图3-2(a)可知, 在 HDTA、LDTA、BTA、RTA 四种模式下, C_{max} 曲线存在很小的差异, 整个网络中的负载数量随着网络中主机数目的增长快速上升; 但在图3-2(b)中, U_{max} 曲线存在比较明显差异。从曲线走势可以看出, 当网络中的主机数量增多时, 网络中负载的分布越来越均匀。在四种模式中, LDTA 有助于使网络中的负载分布更均匀, 而 BTA 效果则最差。通常而言, 如果选择小度的节点作为主机节点时, 这些主机通常位于网络的边缘, 增加了主机到主机传输数据的平均路径长度。从图3-2(c)可以看出这个结论的正确性, 该图还显示 BTA 曲线和 HDTA 曲线基本重合, 在实验中发现, 两种方法选择的主机位置具有很高的重合度。图3-2(d)展示了四种通信模式对网络传输性能的影响, 其中 HDTA 和 RTA 在主机比例较小的情况下表现得比 LDTA 和 BTA 好。

该实验可以得出如下结论: 总体而言, 在 ER 网络中 HDTA、LDTA、BTA、RTA 四种模式对网络的传输能力的影响结果没有很大差别, 但是 HDTA 和 BTA 能够明显提高网络的传输效率 (由于平均传输路径短)。

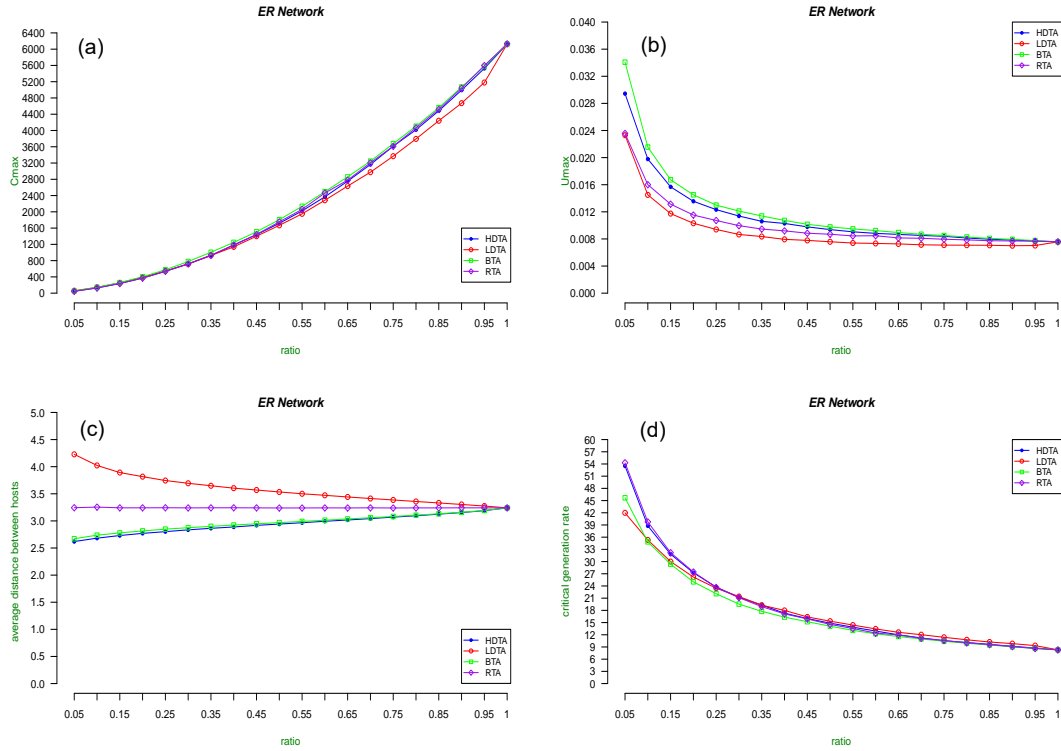


图 3-2 ER 随机网络传输性能实验结果。每个节点的传输能力 $R(i)$ 统一设定为 $R(i) = 100$ 。

图 (a) 表示在四种模式下，最大节点使用次数 C_{max} 随网络中主机比例的变化情况。图 (b) 表示在四种模式下，最大节点使用概率 U_{max} 随网络中主机比例变化的情况。图 (c) 表示在四种模式下，主机到主机间的平均最短距离随网络中主机比例变化的情况。图 (d) 表示在四种模式下，临界数据包生成率 $critical\ generation\ rate (\lambda_c)$ 随网络中主机比例变化的情况。网络的大小为 $N = 500$ 。仿真结果为 100 次实验取平均值。

3.1.2 BA 无标度网络

如图 3-3(a) 所示，对于 BA 网络，在主机数目一样的情况下，采用提到的四种方式选定主机位置时，网络的 C_{max} 不会有太大的差别。而图 3-3(b) 显示当我们选择度小的节点作为主机节点时，网络中的负载能够相对于其他方式更加均匀的分散在网络中的各个节点上。而选择介数中心性大的节点作为主机时，网络的负载在网络中分布最不均匀。图 3-3(c) 显示 BTA 和 HDTA 能够使得网络中数据传输的路径很小，说明网络中数据的传输效率较高；从曲线走势来看，四种方式在主机比例越小时越明显，而针对随机选取主机节点时，网络数据的传输平均路径和网络的平均路径基本一致。图 3-3(b)(c) 表示网络中数据传输的平均路径长度对于负载的分布有直接影响，其表现为更长的数据传输路径能够使得网络负载分布在更多的节点上。从图 3-3(d) 可以看出在主机比例一样时，四种方法对网络的传输能力的影响没有明显的差别，而从曲线的走势可以看出，随着主机

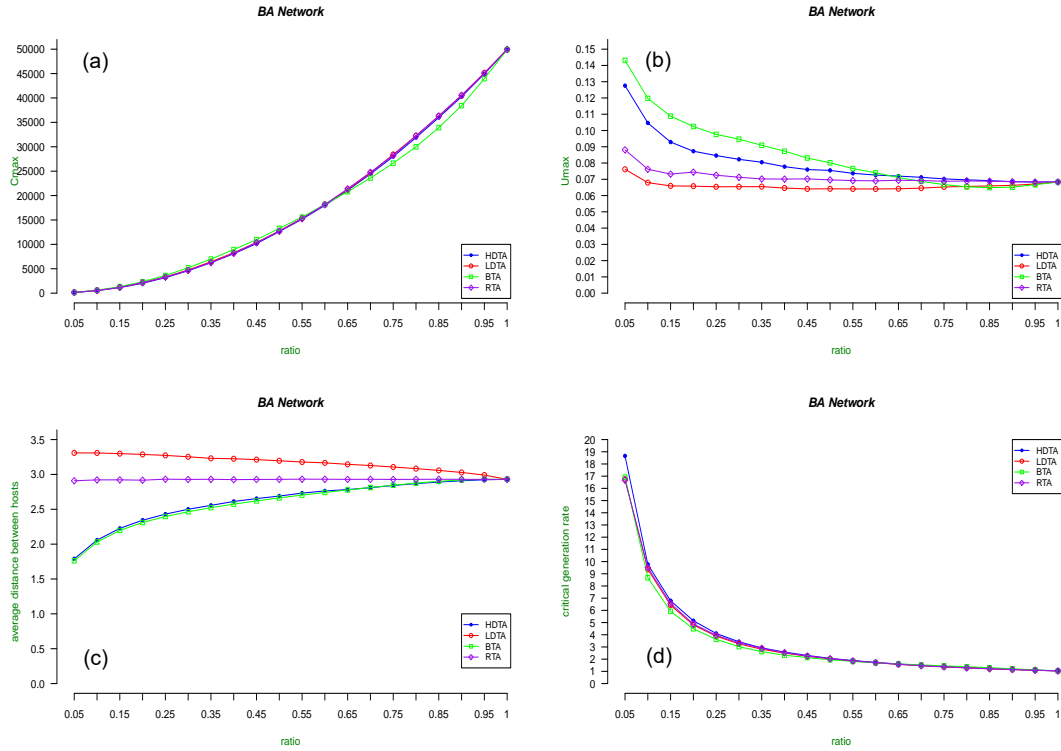


图 3-3 BA 无标度网络传输性能实验结果。每个节点的传输能力 $R(i)$ 统一设定为 $R(i) = 100$ 。图 (a) 表示在四种模式下，最大节点使用次数 C_{max} 随网络中主机比例的变化情况。图 (b) 表示在四种模式下，最大节点使用概率 U_{max} 随网络中主机比例变化的情况。图 (c) 表示在四种模式下，主机到主机间的平均最短距离随网络中主机比例变化的情况。图 (d) 表示在四种模式下，临界数据包生成率 $critical\ generation\ rate (\lambda_c)$ 随网络中主机比例变化的情况。网络的大小为 $N = 500$ 。仿真结果为 100 次实验取平均值。

数量的增加，曲线的斜率越来越大，主机数目对网络的传输性能影响越来越小。

该实验可以得出如下结论：在 BA 网络中 HDTA、LDTA、BTA、RTA 四种模式对网络的传输能力的影响结果没有很大差别，但是 HDTA 和 BTA 能够明显提高网络的传输效率（由于平均传输路径短）。

3.1.3 有社区的 BA 无标度网络

如图3-4(a)所示，对于含有社区的 BA 网络，在主机数目一样的情况下，采用提到的四种方式选定主机位置时，网络的 C_{max} 不会有太大的差别。而图3-4(b)显示当我们选择度小的节点作为主机节点时，网络中的负载能够相对于其他三种方式更加均匀的分散在网络中的各个节点上。而选择介数中心性大的节点作为主机时，网络中的负载在网络中分布最不均匀。图3-4(c)显示 BTA 和 HDTA 能够使得网络中数据传输的路径很小，说明网络中数据的传输效率越高；从曲线走势来看，四种方式在主机比例越小时越明显，而针对随机选取主机节点时，

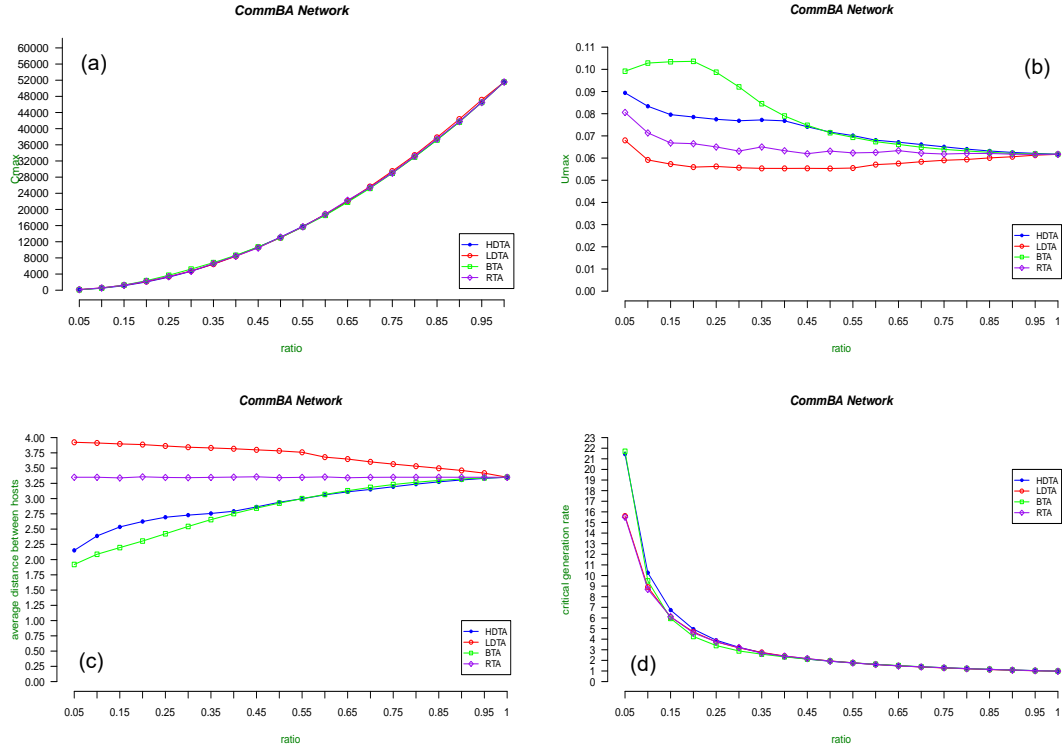


图 3-4 含社区的 BA 网络传输性能实验结果。每个节点的传输能力 $R(i)$ 统一设定为 $R(i) = 100$ 。图 (a) 表示在四种模式下，最大节点使用次数 C_{max} 随网络中主机比例的变化情况。图 (b) 表示在四种模式下，最大节点使用概率 U_{max} 随网络中主机比例变化的情况。图 (c) 表示在四种模式下，主机到主机间的平均最短距离随网络中主机比例变化的情况。图 (d) 表示在四种模式下，临界数据包生成率 $critical\ generation\ rate (\lambda_c)$ 随网络中主机比例变化的情况。网络的大小为 $N = 500$ 。仿真结果为 100 次实验取平均值。

网络数据的传输平均路径和网络的平均路径基本一致。图3-4(b)(c) 表示网络中数据传输的平均路径长度对于负载的分布有直接影响，其表现为更长的数据传输路径能够使得网络负载分布在更多的节点上。从图3-4(d) 可以看出在主机比例一样、主机比例比较大情况下，四种方法对网络的传输能力的影响没有明显的差别，而从曲线的走势可以看出，随着主机数量的增加，曲线的斜率越来越大，主机数目对网络的传输性能影响越来越小。

该实验可以得出如下结论：在含有社区的 BA 网络中 HDTA、LDTA、BTA、RTA 四种模式对网络的传输能力的影响结果没有很大差别，但是 HDTA 和 BTA 能够明显提高网络的传输效率（由于平均传输路径短）。

3.2 主机节点对通信网络鲁棒性的影响

在研究主机位置、数目对通信网络鲁棒性的影响时，为了避免偶然性并得到具有统计价值的结论，我们采取的措施是在 100 个网络中进行鲁棒性实验，这

100 个网络的平均信息如表3-1所示。网络中每个节点在单位时间内节点 i 的传输能力定义为 $Cap(i)$ ，它表征了节点 i 在单位时间内能够传输的最大数据包的数量，通常 $Cap(i)$ 正比于节点 i 初始时的负载 $L(i)$ ，即：

$$Cap(i) = (1 + \alpha)L(i) \quad (3-3)$$

其中 α 为节点 i 的传输冗余参数。节点 i 的负载可以认为是该节点的介数 $B(i)$ 或者是使用次数 $C(i)$ ，在本文中使用 $C(i)$ 来作为节点 i 的初始负载，则节点 i 的传输数据的能力为：

$$Cap(i) = (1 + \alpha)C(i) \quad (3-4)$$

在实验中，设置网络的传输冗余参数 $\alpha = 0.2$ 。

3.2.1 ER 随机网络

图3-5(a)(b)(c) 展示了 C_{max} 、 U_{max} 、主机到主机平均路径与主机数量的关系。其中 C_{max} 和 U_{max} 在四种模式下的差别并不是太明显，但仔细观察能够发现在 HDTA 和 RA 两种模式下 C_{max} 要小一些，而 U_{max} 在 LDTA 和 RA 两种模式下要小一些。在四种模式下， C_{max} 随着主机节点的增加增加，说明网络中某个节点的负载越来越大； U_{max} 随着主机节点的增加而减小，说明网络中的负载分配越来越均匀。

图3-5(d)(e) 中， $Efficiency$ 和 S_{attack} 度量了网络在被蓄意攻击后，网络的性能。在这里，蓄意攻击是指网络中负载最大的节点被移除。当主机数目小于 50 个时，在 LDTA 模式下的网络鲁棒性表现比其他三种模式好。尽管在 LDTA 模式下被攻击的节点负载比其他模式大，攻击后影响的节点数目比其他模式多，但是网络的鲁棒性表现得比其他好。在四种模式下， $Efficiency$ 和 S_{attack} 曲线随着主机数目的增加而减小，网络的鲁棒性和网络的传输效益越差。

图3-5(f)(g)(h) 展示了 ER 随机网络在随机失效时的网络情况。对于网络的传输效益 $Efficiency$ ，在 HDTA 模式下，表现得最好；而在 LDTA 模式下最差；BTA 和 RA 模式下表现非常相似。 $Efficiency$ 的曲线走势为，随着主机数量的增加而减小，然后又增加。对于网络的鲁棒性 $S_{failure}$ ，在主机很少时，四种模式下的鲁棒性差异比较小，但随着主机数目的增加，四种模式的差异逐渐增大。

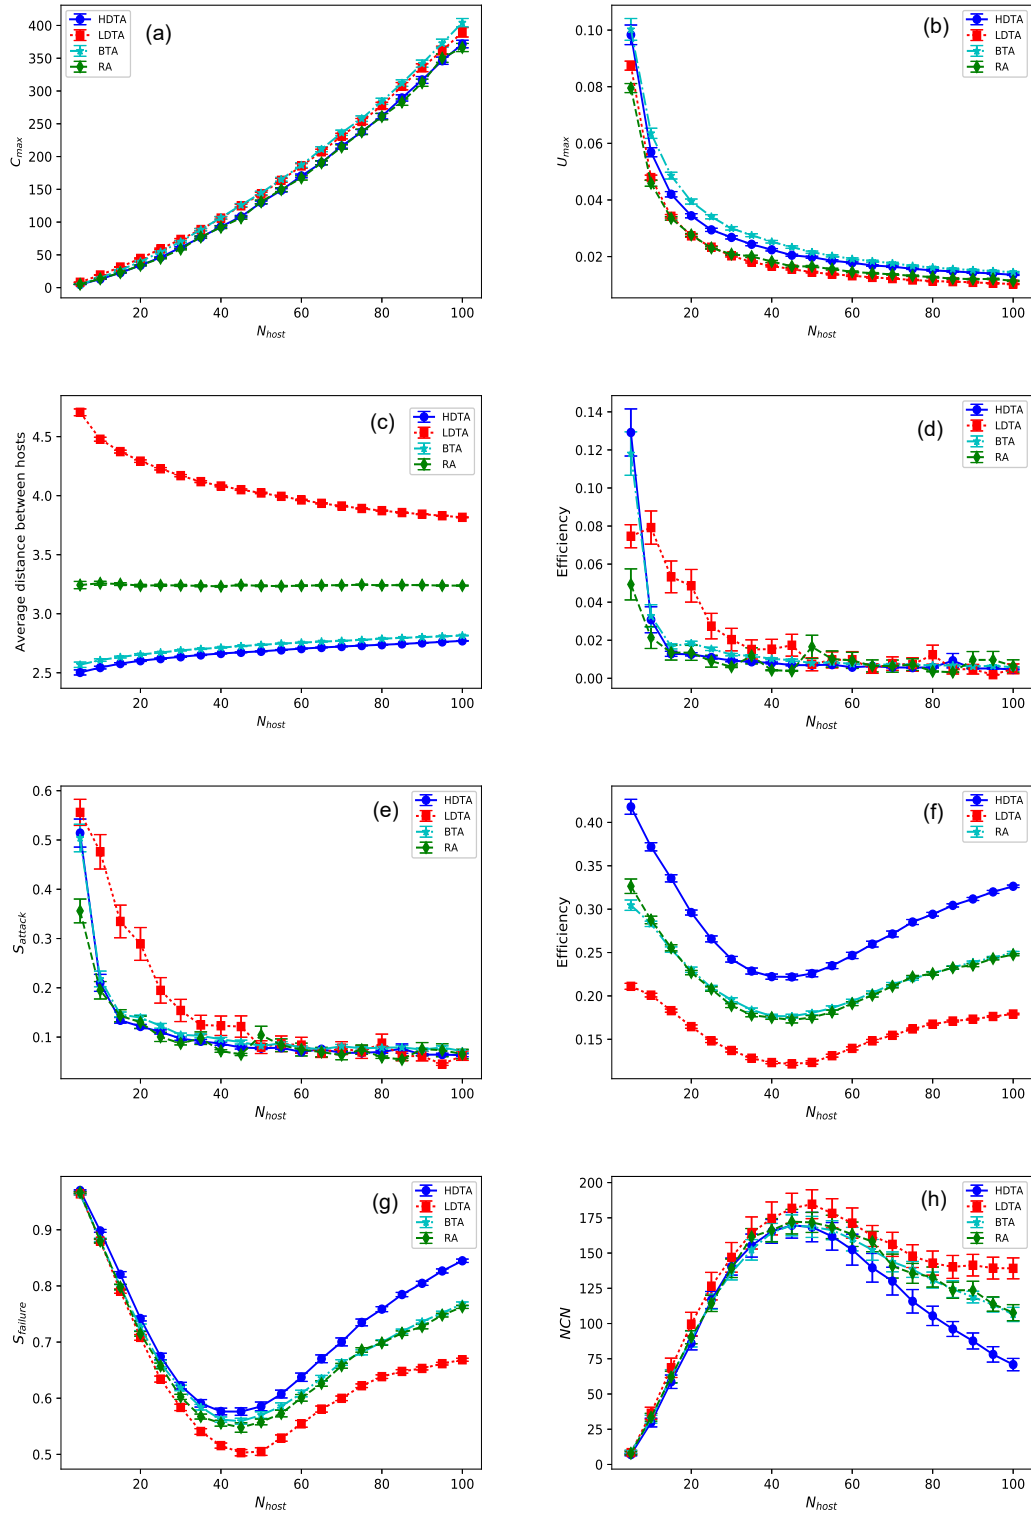


图 3-5 ER 随机网络鲁棒性实验结果。在 (a)(b)(c)(d)(e)(f)(g)(h) 中，横坐标表示主机的数目。(a)(b)(c) 为网络发生级联失效前的最大节点使用次数 C_{max} ，最大节点使用概率 U_{max} ，主机到主机平均最短距离随主机数目变化情况。(d)(e) 为攻击最繁忙节点后的鲁棒性 S_{attack} 和传输效益 $Efficiency$ 。(f)(g)(h) 分别为随机攻击后的鲁棒性 $S_{failure}$ 、传输效益 $Efficiency$ 和关键节点数目 NCN 。网络大小为 $N = 500$ 。每个仿真结果在 100 个网络中进行实验后取平均值。曲线中的 error bars 表示标准误差。

其中 HDTA 模式下的鲁棒性最好, LDТА 模式下最差, BTA 和 RA 模式居中, 且两者的差别很小。 $S_{failure}$ 的曲线走势为, 随着主机数量的增加而减小然后又增加。在随机失效中, 我们设置重要节点的 $threshold = 0.5$, 对于网络中的重要节点 NCN , 在主机很少时, 四种模式下, 网络中的重要节点数目相差不大, 但随着主机数目的增加, 四者差异越来越大。其中在 HDТА 模式下, 重要节点数目最少, 而 LDТА 最多, BTA 和 RA 居中。 NCN 的曲线走势为随着主机数量的增加而增加然后又减少。

在 ER 随机网络中, 对于 HDТА、LDТА、BTA、RA 四种模式, 其中 LDТА 模式在蓄意攻击时的网络鲁棒性比较好, 但是和其他三种模式的区别不是很大。在随机失效时, HDТА 模式的鲁棒性最好, LDТА 最差。BTA 在整个实验中表现出了蓄意攻击时像 HDТА, 随机失效时像 RA。

3.2.2 BA 无标度网络

图3-6(a)(b)(c) 展示了 C_{max} 、 U_{max} 、主机到主机平均路径与主机数量的关系。对于 C_{max} , HDТА 和 BTA 表现出了最好和最差的情况, 但是如果这样认为就太片面, 在通信模式对网络传输性能影响一节中, 图3-6中的 C_{max} 在 BTA 模式下有比 HDТА 好的情况, 当然, 这与网络中主机的数量密切相关。但是我们能够确定的是在 HDТА 和 BTA 两种模式下, 网络中的负载不会均匀的分布在网络中, 网络中的负载只会集中在网络的中心部位。而 RA 和 LDТА 使网络中的负载分布在大量的网络节点中, 使网络负载分布表现出了负载在网络中分布比较均匀。

图3-6(d)(e) 中, $Efficiency$ 和 S_{attack} 度量了网络在被蓄意攻击后, 网络的性能。在这里, 蓄意攻击是指网络中负载最大的节点被移除。从图中可以看出, HDТА 和 BTA 在网络的传输效益和蓄意攻击时的鲁棒性两个方面都表现得较好, 这可以归结为在这两种模式下, 网络中的平均数据传输路径较短, 当节点发生失效时, 影响到的节点比较少, 从而导致最终发生级联失效的节点较少。网络的鲁棒性 S_{attack} 和传输效益随主机数目的增加而减小。

图3-6(f)(g)(h) 展示了 BA 无标度网络在随机失效时的网络情况。对于 $Efficiency$, 在 HDТА 模式下, 整个网络的传输效益表现得最好, 但传输效益随着主机的增加而减小。在 LDТА、BTA、RA 模式下, 网络的传输效益受主机数目影响不大。对于 $S_{failure}$, HDТА 模式的网络鲁棒性最好, 鲁棒性随着主机数目

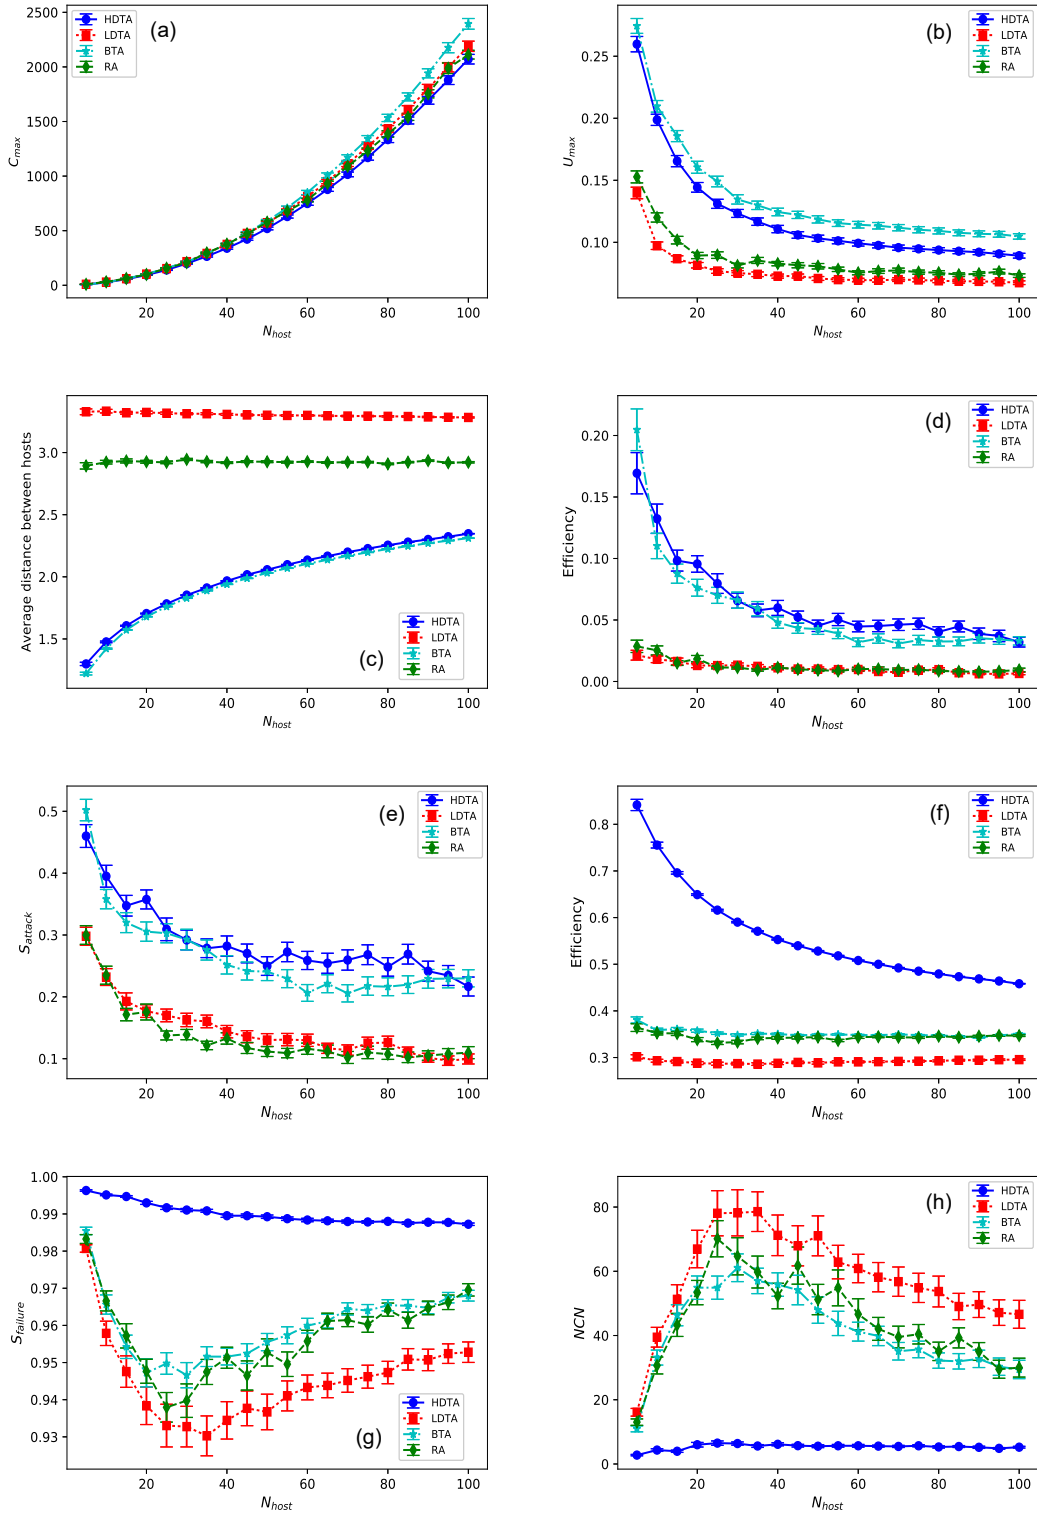


图 3-6 BA 网络鲁棒性实验结果。在 (a)(b)(c)(d)(e)(f)(g)(h) 中，横坐标表示主机的数目。(a)(b)(c) 为网络发生级联失效前的最大节点使用次数 C_{max} ，最大节点使用概率 U_{max} ，主机到主机平均最短距离随主机数目变化情况。(d)(e) 为攻击最繁忙节点后的鲁棒性 S_{attack} 和传输效益 $Efficiency$ 。(f)(g)(h) 分别为随机攻击后的鲁棒性 $S_{failure}$ 、传输效益 $Efficiency$ 和关键节点数目 NCN 。网络大小为 $N = 500$ 。每个仿真结果在 100 个网络中进行实验后取平均值。曲线中的 error bars 表示标准误差。

的增加而下降；而 LDТА、BТА、RА 对应的曲线表现出下降又上升的现象。在随机失效中，我们设置重要节点的 $threshold = 0.5$ 。在 HDTA 模式下，重要节点的数目最少，而其他三种模式相对于 HDTA 模式而言表现较差，对应曲线走势为，随着主机数量增加表现出了先上升又下降的趋势。对于 Efficiency、 S_{attack} 、NCN，在 BТА 模式和 RТА 模式下的表现差别不大。

在 BA 无标度网络中，对于 HDTA、LDТА、BТА 和 RА 四种模式，其中 HDTA 模式在蓄意攻击和随机失效时的网络鲁棒性比较好，而 BТА 模型下的网络在蓄意攻击时的网络鲁棒性很好，但随机失效时的鲁棒性较差。BAT 模式表现出了蓄意攻击时像 HDTA，随机失效时像 RА 的现象。

3.2.3 含有社区的 BA 无标度网络

图3-7(a)(b)(c) 展示了 C_{max} 、 U_{max} 、主机到主机平均路径与主机数量的关系。对于 C_{max} ，HDTA 表现出了最好的情况。在 HDTA 和 BТА 两种模式下，网络中的负载不会均匀的分布在网络中，网络中的负载只会集中在网络的中心部位，而 RА 和 LDТА 使网络中的负载分布在大量的网络节点中，使网络负载分布表现出了负载在网络中分布比较均匀。

图3-7(d)(e) 中， $Efficiency$ 和 S_{attack} 度量了网络在被蓄意攻击后，网络的性能。在这里，蓄意攻击是指网络中负载最大的节点被移除。从图中可以看出，HDTA 在网络的传输效益和蓄意攻击时网络的鲁棒性两方面都表现得较好，这可以归结为在这种模式下，网络中的平均数据传输路径较短，当节点发生失效时，影响到的节点比较少，从而导致最终发生级联失效的节点较少。网络的鲁棒性 S_{attack} 和传输效益随主机数目的增加而减小。

图3-7(f)(g)(h) 展示了含社区的 BA 无标度网络在随机失效时的网络情况。对于 $Efficiency$ ，在 HDTA 模式下，整个网络的传输效益表现得最好，但是传输效益随着主机的增加而减小。在 LDТА、BТА、RА 模式下，网络的传输效益受主机数目影响不大。对于 $S_{failure}$ ，HDTA 模式的鲁棒性最好，网络的鲁棒性随着主机数目的增加缓慢下降，主机数目到达 20 个后曲线趋于平缓。在 LDТА、BТА、RА 对应的曲线表现出了随主机数目增加而快速下降后又缓慢上升的现象。在随机失效中，我们设置重要节点的 $threshold = 0.5$ 。在 HDTA 模式下，重要节点数目最少，而其他三种模式相对于 HDTA 而言较差。四种模式对应的曲线走势为，

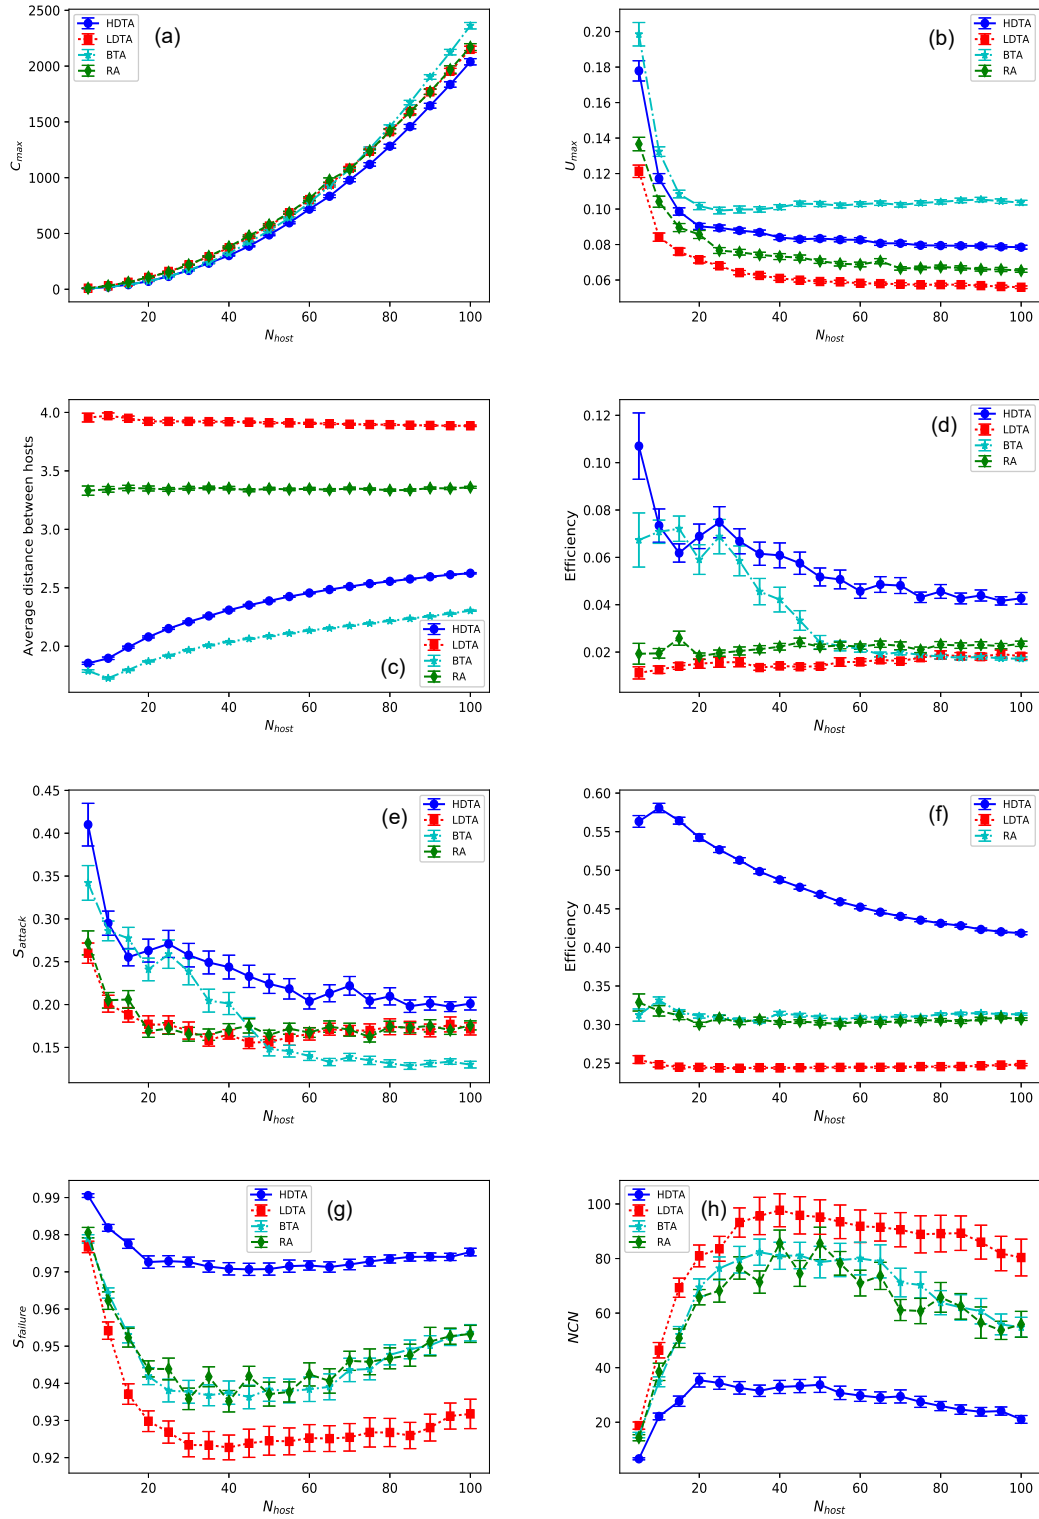


图 3-7 含社区的 BA 网络鲁棒性实验结果。在 (a)(b)(c)(d)(e)(f)(g)(h) 中，横坐标表示主机的数目。(a)(b)(c) 为网络发生级联失效前的最大节点使用次数 C_{max} ，最大节点使用概率 U_{max} ，主机到主机平均最短距离随主机数目变化情况。(d)(e) 为攻击最繁忙节点后的鲁棒性 S_{attack} 和传输效益 $Efficiency$ 。(f)(g)(h) 分别为随机攻击后的鲁棒性 $S_{failure}$ 、传输效益 $Efficiency$ 和关键节点数目 NCN 。网络大小为 $N = 500$ 。每个仿真结果在 100 个网络中进行实验后取平均值。曲线中的 error bars 表示标准误差。

随主机数量增加表现出了先上升又下降的趋势。对于 $Efficiency$ 、 S_{attack} 、 NCN ，在 BTA 模式和 RTA 模式下的表现差别不大。

在含有社区的 BA 无标度网络中，对于 HDTA、LDTA、BTA、RA 四种模式。其中 HDTA 模式在蓄意攻击和随机失效时的网络鲁棒性比较好。BTA 模型下的网络在随机失效时， $Efficiency$ 、 $S_{failure}$ 和 NCN 的曲线像 RA 模式下的曲线。

3.3 结束语

本章主要研究了四种模式 HDTA、LDTA、BTA 和 RA 对 ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络的性能的影响。我们分别从网络的传输性能和网络鲁棒性出发，着手研究主机位置的不同对网络性能的影响。

在网络传输性能实验中，采用 λ_c 来衡量网络的传输性能。实验得出的主要结论为：当网络中每个节点的传输能力一样时，HDTA、LDTA、BTA 和 RA 对网络传输性能的影响不存在明显差异，差异稍微明显的情况是在主机比例小于 0.3 的情况下。在传输效益方面，HDTA 和 BTA 表现甚好，甚至有基本一致的情况。

在网络鲁棒性实验中，我们考虑了在蓄意攻击和随机失效情况下网络的鲁棒性，分别用 S_{attack} 和 $S_{failure}$ 来衡量网络的鲁棒性。在蓄意攻击实验中得出的主要结论为：ER 随机网络在 LDTA 模式下的鲁棒性总体而言会好一些，ER 网络中 BTA 模式和 HDTA 模式对应的 $Efficiency$ 和 S_{attack} 曲线基本重合。BA 无标度网络在 HDTA 模式下的鲁棒性总体而言要好一些，网络中 BTA 模式和 HDTA 模式对应的 $Efficiency$ 和 S_{attack} 曲线所在位置非常接近。含社区的 BA 无标度网络在 HDTA 模式下的鲁棒性总体而言要好很多。在随机失效的实验中得出的主要结论为：三种网络中，在 HDTA 模式下的鲁棒性是最好的，但在 ER 随机网络中 LDTA、BTA 和 RA 模式下的鲁棒性与 HDTA 模式下差别不是太大。在 BTA 模式下对应的 $Efficiency$ 、 $S_{failure}$ 和 NCN 曲线与 RTA 对应的曲线重合度较高。

第四章 通信网络性能优化

在论文^[14]中，作者采用了模拟退火算法对网络进行性能优化，从优化化结果来看，模拟退火能取得不错的结果。但在大规模复杂网络盛行的今天，如何提高算法速度对网络进行优化，是值得深入研究的。其中提高算法效率的一种方法是实现算法的并行化，让一个问题能够在多台服务器、多个 CPU 上进行计算，从而提高解决问题的能力。模拟退火的弊端就在于不能实现并行化，而粒子群优化算法是可并行化的优化算法。所以本章除了研究优化后的网络具有怎样的特点外，还对并行化的粒子群算法进行了实验，对比了模拟退火和粒子群优化算法的优化速度。

4.1 基于传统启发式算法优化简单通信网络

本小节将对简单网络性能进行优化。优化的网络为 BA 网络，含有主机和路由器两种节点。在对网络传输性能 λ_c 进行优化中，优化的网络含有 500 个节点，包含 100 个主机节点，每个节点的传输能力为 $R = 100$ 。在对网络鲁棒性进行优化中，优化的网络含有 300 个节点，包含 30 个主机，每个节点的传输冗余参数 $\alpha = 0.2$ 。

4.1.1 基于模拟退火的网络优化

本小节将采用模拟退火对网络的传输性能和网络的鲁棒性进行优化。伪代码参考第四章 2.2，优化算法的流程图为 4-1。

在实验中，加入了贪心算法进行对比实验。贪心算法的思路是当改变一个主机的位置能够得到更好的适应度时，我们就接受这个位置，否则舍弃这个位置。在实验中，将模拟退火的温度设置很低时，模拟退火算法就成为了贪心算法。

4.1.2 基于粒子群优化方法的网络优化

该小节将采用基于集合的综合学习粒子群算法 (A Novel Set-Based CLPSO, S-CLPSO) 对网络的传输性能和鲁棒性进行优化。S-CLPSO 速度更新如图所

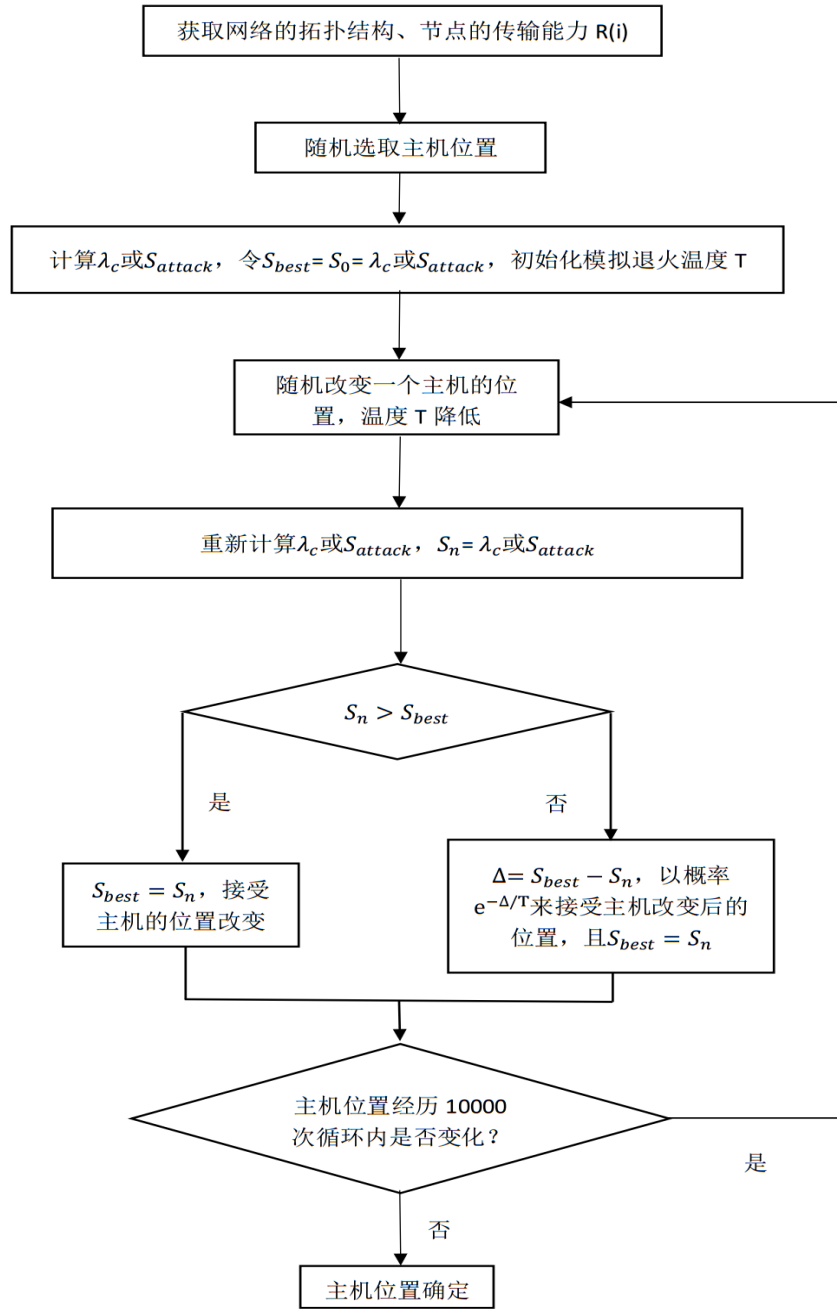


图 4-1 模拟退火算法流程图

示4-2。

1) 粒子群的初始化

在初始化粒子群时，随机从网络中选择 N_{host} 个位置作为一个粒子的状态 $X_i = (x_i^1, x_i^2, \dots, x_i^{N_{host}})$ ，在我们的网络优化问题中，优化的目标属于组合问题，所以状态 $X_i = (x_i^1, x_i^2, \dots, x_i^{N_{host}})$ 和状态 $X_i = (x_i^{N_{host}}, \dots, x_i^2, x_i^1)$ 是等价的，即状态 X_i 与状态集合中的元素顺序没有关系。对于粒子群各粒子的初

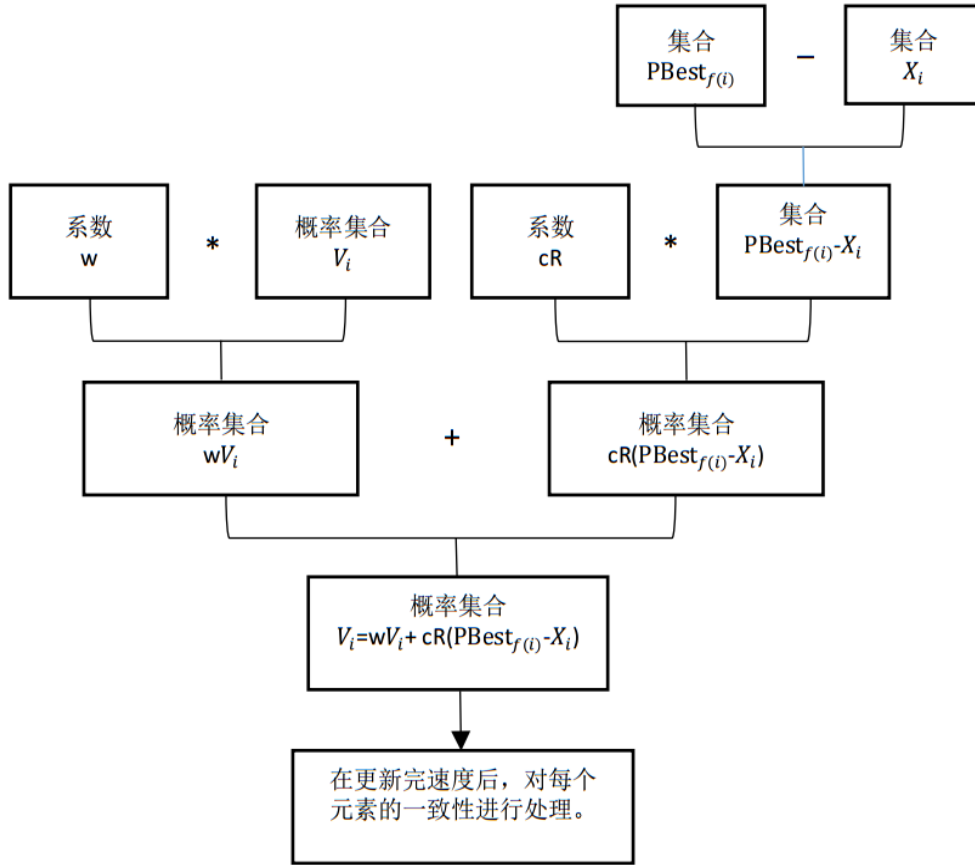


图 4-2 S-CLPSO 速度更新框图。具体运算规则参见 23 页。

始化方式, 粒子位置从解空间随机选取, 即随机从网络中选择 N_{host} 个节点放置主机。初始化的粒子 i 的速度为 $V_i = ((x_i^1, p_i^1), (x_i^2, p_i^2), \dots, (x_i^{N_{host}}, p_i^{N_{host}}))$, 其中, p_i 是 $(0,1]$ 的随机数构成的集合, $x_i^1, x_i^2, \dots, x_i^{N_{host}}$ 随机从解空间中选取。

2) 粒子速度更新

速度更新公式为:

$$V_i = wV_i + cR(Pbest_{f(i)} - X_i) \quad (4-1)$$

其中 R 为在 $(0,1]$ 区间内随机生成的随机数所构成的集合, 集合中元素个数为 $Pbest_{f(i)} - X_i$ 集合中的元素个数。假如 $R = (r_1, r_2)$, $Pbest_{f(i)} - X_i = (x_1, x_2)$, 那么 $R * (Pbest_{f(i)} - X_i) = ((x_1, r_1), (x_2, r_2))$ 。 $Pbest_{f(i)}$ 是粒子 $f(i)$ 最好位置。 $f(i)$ 的确定流程如下。随机数 ran 从区间 $[0,1]$ 随机生成, 如果

算法 4.1 基于 S-CLPSO 的网络性能优化算法

```

1: procedure S-PSO
2: step1:
3:    $k = 1$ 
4:    $M \leftarrow$  swarm size
5:    $iteration \leftarrow$  iteration times
6:    $w \leftarrow$  inertia weight to velocity updating
7:    $c \leftarrow$  importance of social-influence
8:    $P_c \leftarrow$  The possibility of learning from Pbest.
9:   Initial_Every_Particle()
10:  Particle_Function()
11: step2:
12:  Velocity_Updating()
13:  Positon_Updating()
14:  Particle_Function()
15:   $k = k + 1$ 
16:  if stopping condition = true then
17:    STOP
18:  else
19:    go to Step 2
20:  end if
21: end procedure

```

ran 比参数 P_{C_i} 大, $f(i) = i$ 。否则, 采用锦标赛法则从随机选择的两个粒子中确定, 具有较好适应度的粒子作为 $f(i)$ 。该方法使得 $Pbest_{f(i)}$ 能够学习任何粒子的最好的位置。 P_{C_i} 设为:

$$P_{C_i} = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1} - 1}}{e(10) - 1} \quad (4-2)$$

在进行速度更新的步骤中, 对于带有概率的速度集合 V_i 将转换为供位置更新的集合 $cut_\alpha(V_i)$ 。在位置更新的过程中, 粒子 i 首先从 V_i 中找出希望学习的元素。其次, 每个粒子在区间 (0,1] 随机产生一个随机数 α 。最后, 若速度 V_i 中元素对应的 $p(e)$ 不小于 α , 那么将元素 $(e, p(e))$ 保存到集合 $cut_\alpha(V_i)$ 中。

$$cut_\alpha(V_i) = \{(e, p(e)) \in V_i \text{ and } p(e) \geq \alpha\} \quad (4-3)$$

很显然, 越大的 $p(e)$, 说明 $(e, p(e))$ 被保存到集合 $cut_\alpha(V_i)$ 的机会就越大。粒子将从该元素学习来建立新的位置。例如, $V_i = \{(1, 0.3), (2, 0.7)\}$, $\alpha = 0.5$, 则 $cut_\alpha(V_i) = \{(2, 0.7)\}$

3) 粒子位置更新

粒子 i 将从 $cut_\alpha(V_i)$ 学习，然后建立一个新的位置。粒子建立新位置的方法为：如果 $cut_\alpha(V_i)$ 元素个数大于 N_{host} ，选取概率最大的前 N_{host} 位置放置主机；如果 $cut_\alpha(V_i)$ 元素个数小于 N_{host} ，将 $cut_\alpha(V_i)$ 中所有元素作为位置来放置主机，剩余的位置从粒子上一次的位置随机选取。

4.1.3 实验对比分析

1) 网络传输性能优化




图 4-3 临界数据包生成率的优化过程。横坐标为时间，单位为半秒。

在图4-3中，每种算法均是在同一个 BA 无标度网络中进行试验，该网络有 500 个节点，1988 条边，主机的数目为 100 个。在实验中进行了多次试验，通过调参，选取了最好的结果在图中展示。其中横坐标为时间，单位为半秒。红色曲线为选择高度节点的结果，对应的 λ_c 为 2.62182。蓝色曲线为贪心算法，最后优化得到的结果为 8.52713。橙色曲线为模拟退火算法，初始温度设定值为 1，温度下降公式为 $T = 0.99992T$ ，最终优化得到的结果为 9.90991。绿色曲线为基于集合的综合学习粒子群算法，种群设定为 30 个， $w = 1, \Delta w = 0.001, c = 4, w$ 值降到 0.4 时保持不变， $Pc_i = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1}-1}}{e^{(10)-1}}$ ，最终优化得到的值为 9.90991。

对实验结果进行分析，贪心算法的收敛速度最好，但是最终结果相对于 SA 和 S-CLPSO 而言最终结果较差。HDTA 通过选取度最高的节点来放置主机

的方法相对于其他三种方法显得太差。

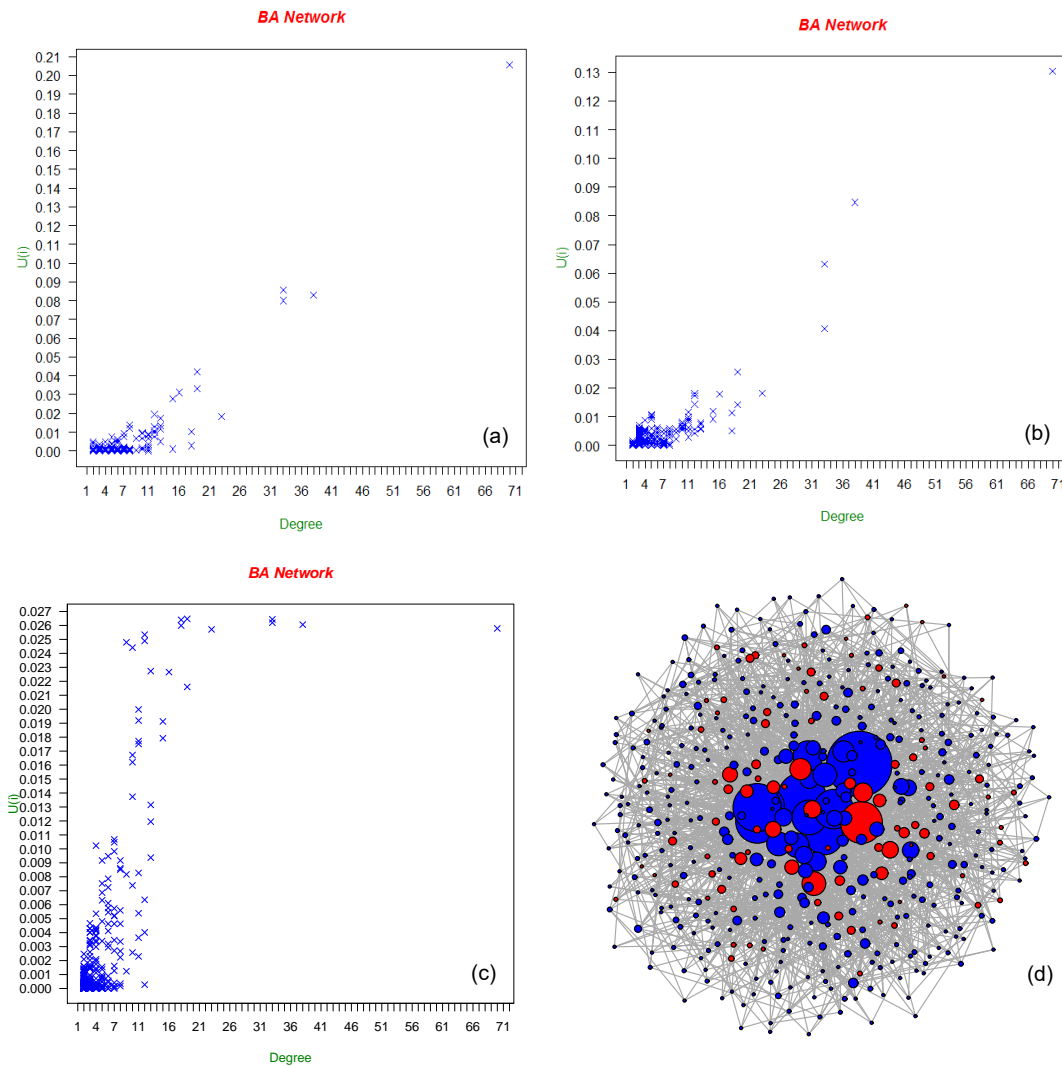


图 4-4 (a)(b) 分别为 HDTA、LDTA 模式下的节点使用概率分布。(c) 为模拟退火优化后的节点使用概率分布。(d) 为模拟退火后，网络中主机节点的位置，红色节点表示主机。

图4-4(a)(b)(c)展示了在 HDTA、LDTA 和 SA 优化后的 $U(i)$ 的分布图，很明显 SA 使得网络中的负载均匀的分布在网络中。图4-4(d)展示了网络在模拟退火优化后，主机在网络中的位置，越大的节点表示度越大。对于 SA 优化后的网络，主机的位置并没有选择那些度很大的点。图4-5显示了 SA 优化过程中主机间平均最短距离随时间的变化过程，其中 D 表示网络的平均最短路径长度。在优化开始时，由于随机选取主机的位置，所以优化算法开始时，主机间的平均最短路径的长度和网络的平均最短路径长度相近。随着优化过程的不断进行，优化过程中主机间平均最短路径长度趋向于变大。优化网络后，主机间的平均最短路径长度几乎与 LDTA 的相同。




图 4-5 模拟退火优化临界数据包生成率过程中，主机到主机的平均最短距离变化。横坐标为时间，单位为半秒。

2) 网络鲁棒性优化




图 4-6 蓄意攻击时，网络鲁棒性的优化过程。横坐标为时间，单位为两秒。

在鲁棒性优化实验中，我们同网络传输优化实验一样，对比了贪心算法、模拟退火算法、基于集合的综合学习粒子群算法和 HDTA 的实验结果。鲁棒性 S_{attack} 优化过程如图4-6所示。每种算法均是在同一个 BA 网络中进行实验。实验的网络有 300 个节点，597 条边，主机数目为 30 个。在实验中进行多次调参，选取最好的结果在图中进行展示。其中横坐标为时间，单位为两秒，纵坐标为蓄意攻击时网络的鲁棒性参数。红色曲线为选择高度节点作为主机的结果，对应的 $S_{attack} = 0.333333$ 。蓝色曲线为贪心算法，在实验中我们

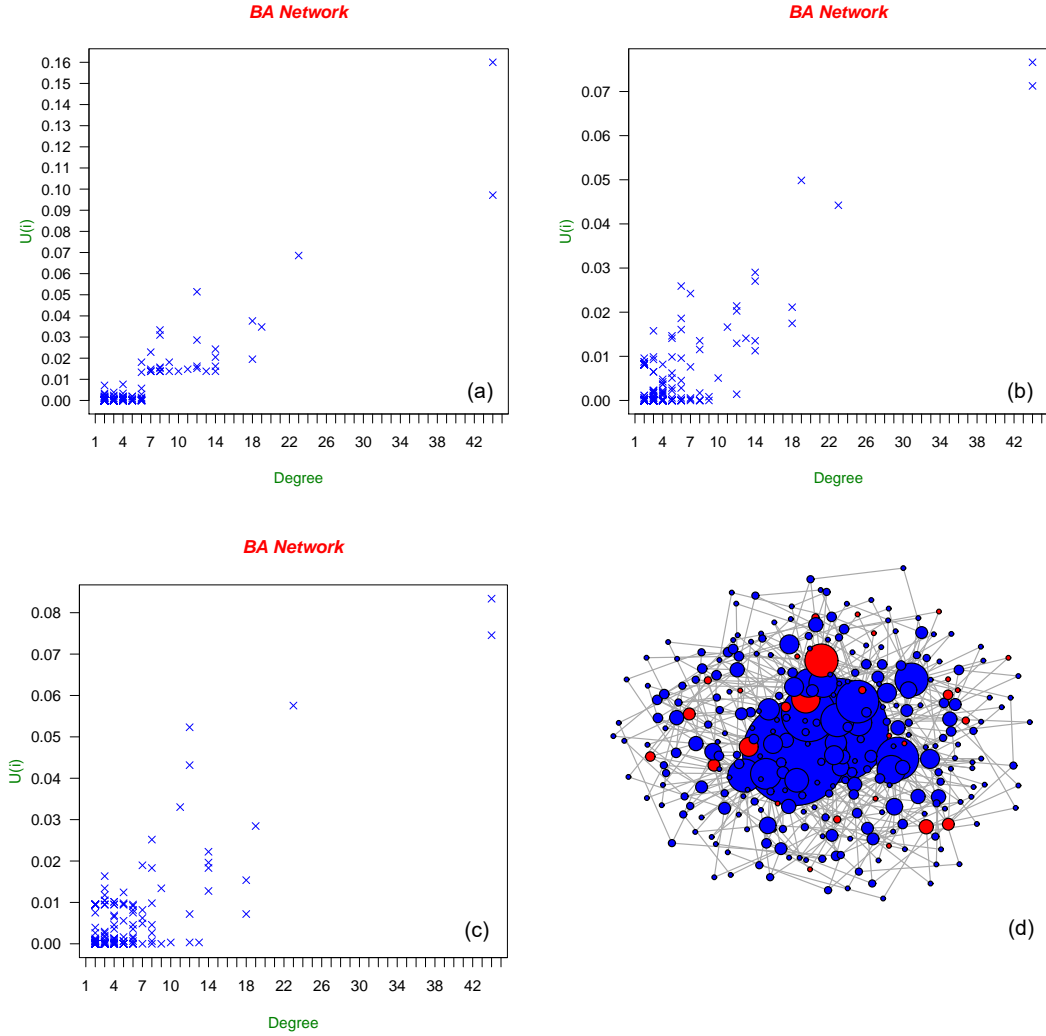


图 4-7 (a)(b) 分别为 HDTA、LDTA 模式下的节点使用概率分布。(c) 为模拟退火优化后的节点使用概率分布。(d) 为模拟退火后，网络中主机节点的位置，红色节点表示主机。

随机的改变网络中主机的位置，如果改变后的位置能够使得网络在被蓄意攻击时的鲁棒性变好，则接受该位置。若在重复改变位置 15000 次后网络鲁棒性不再改变，则优化过程终止。贪心算法的优化结果为 $S_{attack} = 0.766667$ 。橙色曲线为模拟退火算法，初始温度设置为 $T_0 = 10$ ，温度下降公式为 $T = 0.999T$ ，最终优化的结果为 $S_{attack} = 0.9$ 。绿色曲线为基于集合的综合学习粒子群算法，种群设定为 20 个， $w = 1, \Delta w = 0.001, c = 4$ ， w 降到 0.4 时不再改变， $Pc_i = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1}-1}}{e^{(10)-1}}$ ，最终优化结果为 $S_{attack} = 0.9$ 。

对实验结果进行分析，贪心算法的收敛速度最好，但是最终结果相对于 SA 和 S-CLPSO 而言最终结果较差。HDTA 通过选取度最高的节点来放置主机的方法相对于其他三种方法显得太差。




图 4-8 模拟退火优化蓄意攻击时的网络鲁棒性过程中，主机到主机的平均最短距离变化。横坐标为时间，单位为秒。

图4-7(a)(b)(c)展示了 HDTA、LDTA、和 SA 优化后的网络 $U(i)$ 分布图。SA 优化后的网络负载比较均匀的分布在网络中，但是没有 LDTA 那么好，也不像在对网络传输性能优化那样，SA 会很大程度的将负载均匀分布在网络中。图4-7(d)展示了模拟退火优化后主机在网络中的位置，越大的节点表示度越大。对于 SA 优化后的主机位置，主机的位置并没有选择那些度很大的点。图4-8显示了 SA 优化过程中主机间平均最短距离随时间的变化过程，其中 D 表示网络的平均最短路径长度。在优化开始时，由于主机的位置是随机选取的，所以优化算法开始时，主机间的平均最短路径的长度和网络的平均最短路径相近。随着优化过程的不断进行，优化过程中主机间平均最短路径长度曲线在网络的平均最短路径长度直线附近上下波动。当优化过程到图中所示的红点处时，网络在蓄意攻击下的鲁棒性 $S_{attack} = 0.9$ 。此后，网络在蓄意攻击下的鲁棒性 S_{attack} 保持在 0.9，但网络中主机到主机的最短路径长度仍然在变化着。这是因为当模拟退火算法在改变一个主机的位置时，若 $S_{attack} = 0.9$ ，算法将接受该主机的位置。这种现象说明，在蓄意攻击下，优化后的网络鲁棒性与网络中主机到主机的平均最短路径长度没有明显的关系。

3) 代码设计中的算法优化问题

整个论文中的实验均是用 C++ 代码实现，其中涉及到最基本的图论数据结

构、最短路径算法、介数中心性算法、优化算法等的实现。在这里将对算法的效率进行思考。对于图论数据结构，主要是设计一个数据结构来存储网络节点和连边信息，该数据结构主要有两种：邻接矩阵和邻接表。邻接矩阵在计算时非常方便查询，但是当存储的是一个稀疏图时，邻居矩阵非常浪费空间。如果需要查询一个节点的邻居需要遍历矩阵的一列或一行，无形中增加了时间复杂度。邻接表是非常适用于稀疏网络的数据结构。如果在存储空间足够用的情况下，可以同时采用两个数据结构来提高程序的运算效率。图论中的最短路径算法主要有四种：Dijkstra、Floyd、Bellman-ford 和 SPFA。Dijkstra 作为一种单源最短路径算法，运行一次可以计算出一个网络节点到所有网络节点的最短路径，只适用于没有负权边的网络。Dijkstra 计算网络中所有最短路径的时间复杂度为 $O(|V|^3)$ ，如果用优先队列、斐波那契堆对 Dijkstra 算法进行优化，时间复杂度能够降到 $O(\log(|V|)|V|^2)$ 、 $O(E + \log(|V|)|V|)$ 。Floyd 算法作为一种多源最短路径算法，调用一次可以计算出图中所有最短路径，采用的是动态规划的思想，可以处理有负权边的图，时间复杂度为 $O(|V|^3)$ 。Bellman-ford 算法作为一种单源最短路径算法，调用一次只能计算一个节点到网络所有节点的最短路径，可以判断网络有无负权回路，时间复杂度为 $O(|V||E|)$ 。Bellman-ford 计算网络中所有节点最短路径的时间复杂度为 $O(|V|^2|E|)$ 。Bellman-ford 算法和 Dijkstra 算法很像，区别在于 Bellman 算法在求出最短路径后还要判断该最短路径是否能对边进行松弛。SPAF 算法是 Bellman-ford 算法的优化版，采用了队列进行优化，该算法在稀疏图中表现良好，也适用于含有负权边的情况，缺点是算法效率不稳定，如果是在不含有负权边的网络中，最好选择 Dijkstra 算法。SPFA 算法除了是对 Bellman-ford 算法的优化以为，自身也有两种优化方式，分别为：small label first 策略 (SLF) 和 large label last 策略 (LLL)。SLF：对于要加入队列的节点 m ，队列首元素为 n ，如果 $d[m] < d[n]$ ，则将 m 插入队首。这种方法的效率大概能提高 20% 左右。LLL：对于要插入的节点 m ，队列中所有距离值得平均值为 \bar{d} ，如果 $d[m] > \bar{d}$ ，则将 m 插入队尾。如果 $d[m] \geq \bar{d}$ ，查找队列中的元素，如果 $d[n] \leq \bar{d}$ ，则将 n 出队进行松弛操作。

4.2 基于解特征的启发式算法优化简单通信网络

在该小节，我们根据上一小节的优化结果提出了基于解特征的启发式算法。分别为：基于解特征的模拟退火算法 (F-SA) 和基于解特征的基于集合的综合学习粒子群算法 (F-S-CLPSO)。该启发式算法用于优化 BA 网络的传输性能和现实 AS 自治系统网络得到不错效果，算法的优化时间得到较大提升。在上一小节中，我们对优化传输性能后的 BA 网络进行了分析，发现网络中的主机放置与 LDTA 模式下具有很高的相似性。具体体现在，主机到主机的平均最短距离与 LDTA 模式下相近，这种现象说明选择的主机位置有趋向于选择度小节点的行为，从4-4(d)可以看出该特点。因此我们设计了具有针对性的启发式算法，在算法中引入节点选择的权重机制，对模拟退火和基于集合的综合学习粒子群算法的随机选择机制进行修改。权重机制如下：

在一个 BA 网络中，最高度为 k_h ，最低度为 k_l 。对于节点 i ，其度为 k_i 。选择节点 i 作为主机的权重 w_i 为：

$$w_i = \left(\frac{k_i}{k_l - k_h} + \frac{k_h}{k_h - k_l} \right)^\alpha = \left(\frac{k_h - k_i}{k_h - k_l} \right)^\alpha, \quad (4-4)$$

其中 α 为可调参数。所有节点被选权重之和 w_{total} 为：

$$w_{total} = \sum_{i=0}^N w_i, \quad (4-5)$$

从网络中选择节点 i 作为主机的概率 p_i 为：

$$p_i = \frac{w_i}{w_{total}}, \quad (4-6)$$

4.2.1 基于解特征的模拟退火算法

在该小部分，我们提出了一种基于解特征模拟退火算法 (F-SA) 对 BA 网络的传输性能进行优化。与传统模拟退火算法的区别在于：

- 1、在初始化时，初始化的解具有符合目标解的特征。这样的初始解使得网络相对于随机选择位置具有较好传输性能。

2、在尝试更改网络中主机位置时，基于解特征的权重机制能够使算法大量的去尝试具有目标解特征的待测解。

算法流程图如图4-9。

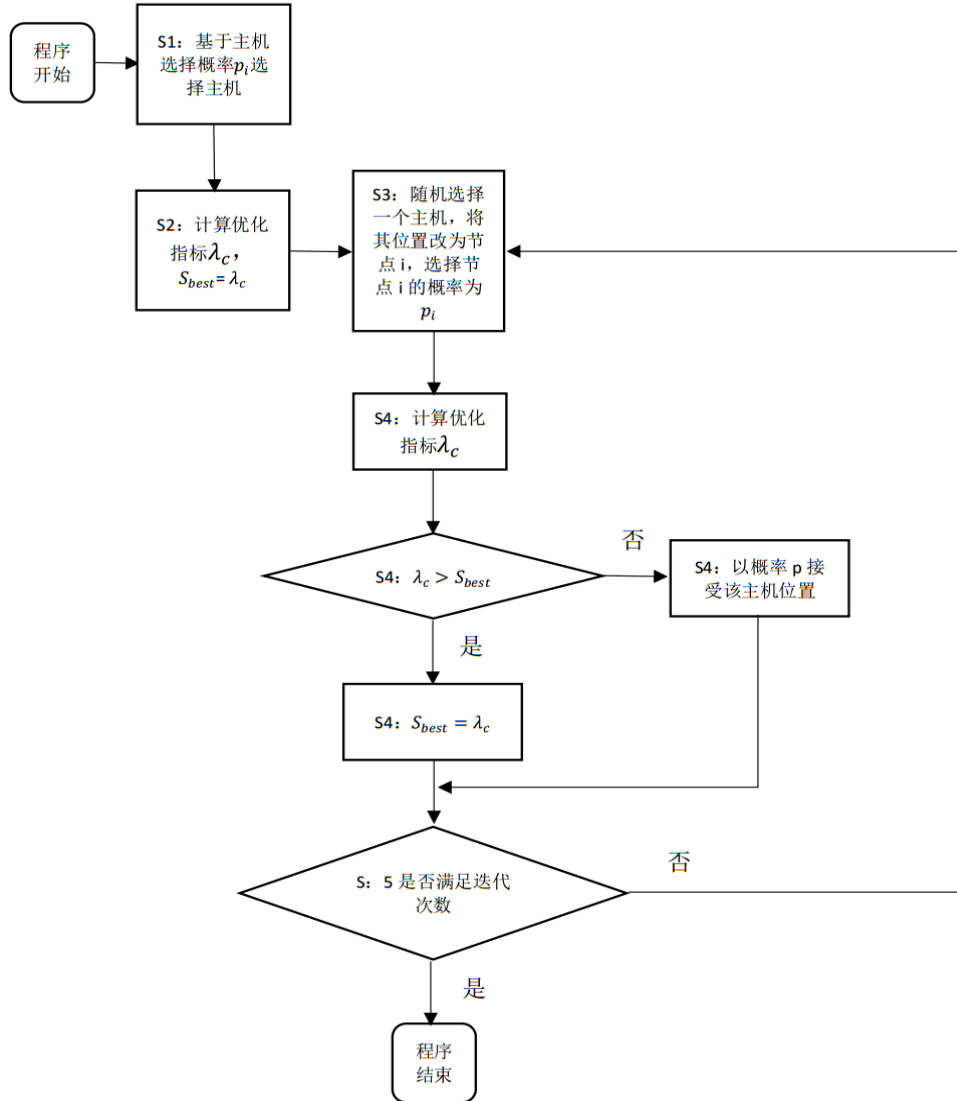


图 4-9 基于解特征的模拟退火算法流程图。其中概率 $p = e^{\frac{S_{best} - \lambda_c}{T}}$ ，温度 T 随迭代次数增加而降低。

4.2.2 基于解特征的 S-CLPSO 算法

该小部分，我们提出一种基于解特征的 S-CLPSO 算法 (F-S-CLPSO) 对 BA 网络的传输性能进行优化。与传统 S-CLPSO 算法的区别在于：

- 1、在初始化粒子的位置时，初始化的位置具有符合目标解的特征。
- 2、在位置初始化时，速度中的概率值受权重系数影响。

F-S-CLPSO 算法具体实现描述如下：

1) 粒子群的位置初始化

在初始化粒子群位置时, 需要从网络中选取 N_{host} 个位置作为粒子 i 的状态 $X_i = (x_i^1, x_i^2, \dots, x_i^{N_{host}})$, 其中 $x_i^1, x_i^2, \dots, x_i^{N_{host}}$ 为网络中节点的标号。选择节点 j 作为主机的概率 p_j 与其度 k_j 成负相关关系, $p_j = \frac{w_j}{w_{total}}$ 。

2) 粒子群的速度初始化

在初始化粒子群的速度时, 首先从网络中选取 N_{host} 个位置, 选取方式与初始化粒子位置方式一样。对于选取的位置, 生成一个概率与其构成一个二元组, 即粒子 i 的速度为 $V_i = ((x_i^1, \bar{p}_i^1), (x_i^2, \bar{p}_i^2), \dots, (x_i^{N_{host}}, \bar{p}_i^{N_{host}}))$, 二元组 (x_i^j, \bar{p}_i^j) 中 $\bar{p}_i^j = w_{x_i^j} * p_i^j$, p_i^j 是 $(0,1]$ 的随机数。

3) 粒子速度更新

速度更新公式为:

$$V_i = wV_i + cRW(Pbest_{f(i)} - X_i) \quad (4-7)$$

其中 R 为在 $(0,1]$ 区间内随机生成的随机数所构成的集合, 集合中元素个数为 $Pbest_{f(i)} - X_i$ 集合中的元素个数。 W 中元素分别与集合 $Pbest_{f(i)} - X_i$ 中位置一一对应, 为主机 i 的被选择权重 w_i 。假如 $R = (r_1, r_2)$, $W = (w_{x_1}, w_{x_2})$, $Pbest_{f(i)} - X_i = (x_1, x_2)$, 那么 $R * W * (Pbest_{f(i)} - X_i) = ((x_1, r_1 * w_{x_1}), (x_2, r_2 * w_{x_2}))$ 。 $Pbest_{f(i)}$ 是粒子 $f(i)$ 最好位置。 $f(i)$ 的确定流程如下。随机数 ran 从区间 $[0,1]$ 随机生成, 如果 ran 比参数 Pc_i 大, $f(i) = i$ 。否则, 采用锦标赛法则从随机选择的两个粒子中确定, 具有较好适应度的粒子作为 $f(i)$ 。该方法使得 $Pbest_{f(i)}$ 能够学习任何粒子的最好的位置。 Pc_i 设为:

$$Pc_i = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1}-1}}{e^{(10)} - 1} \quad (4-8)$$

在进行速度更新的步骤中, 对于带有概率的速度集合 V_i 将转换为供位置更新的集合 $cut_\alpha(V_i)$ 。在位置更新的过程中, 粒子 i 首先从 V_i 中找出希望学习的元素。其次, 每个粒子在区间 $(0,1]$ 随机产生一个随机数 α 。最后, 若速度 V_i 中元素对应的 $p(e)$ 不小于 α , 那么将元素 $(e, p(e))$ 保存到集合 $cut_\alpha(V_i)$

中。

$$cut_{\alpha}(V_i) = \{(e, p(e)) \in V_i \text{ and } p(e) \geq \alpha\} \quad (4-9)$$

很显然, 越大的 $p(e)$, 说明 $(e, p(e))$ 被保存到集合 $cut_{\alpha}(V_i)$ 的机会就越大。粒子将从该元素学习来建立新的位置。例如, $V_i = \{(1, 0.3), (2, 0.7)\}$, $\alpha = 0.5$, 则 $cut_{\alpha}(V_i) = \{(2, 0.7)\}$

4) 粒子位置更新

粒子 i 将从 $cut_{\alpha}(V_i)$ 学习, 然后建立一个新的位置。粒子建立新位置的方法为: 如果 $cut_{\alpha}(V_i)$ 元素个数大于 N_{host} , 选取概率最大的前 N_{host} 位置放置主机; 如果 $cut_{\alpha}(V_i)$ 元素个数小于 N_{host} , 将 $cut_{\alpha}(V_i)$ 中所有元素作为位置来放置主机, 剩余的位置从粒子上一次的位置随机选取。

4.2.3 权重机制参数 α 分析实验

为了分析权重机制参数 α 对算法的影响, 我们选择了一个含有 500 个节点, 1988 条边的 BA 网络进行实验。每一个 α 值进行 30 次实验取平均值。实验结果如图4-10。实验中, SA 和 F-SA 算法的初始温度设定值为 1, 温度下降公式为 $T = 0.99992T$, 优化目标 λ_c 在迭代 1000 次不变时, 算法停止。S-CLPSO 和 F-S-CLPSO 算法中, 种群设定为 30 个, $w = 1, \Delta w = 0.001, c = 4, w$ 值降到 0.4 时保持不变, $Pc_i = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1}} - 1}{e^{(10)} - 1}$, 优化目标 λ_c 在迭代 300 次保持不变时, 算法停止。

图4-10(a) 为 F-SA 算法相对于 SA 算法和 F-S-CLSPO 算法相对于 S-CLPSO 算法的时间效率, $\eta = 20$ 表示 F-SA 算法相对于 SA 算法或 F-S-CLPSO 算法相对于 S-CLPSO 算法的时间效率提高了 20%。从图可以看出, 随着 α 值得增加, 导致 F-SA 算法和 F-S-CLSPO 算法搜索解越来越倾向于搜索度小的节点, 基于解特征的启发算法的时间效率逐渐提升。

图4-10(b) 为 F-SA 和 F-S-CLSPO 算法优化效果随 α 变化情况。从图可以看出, α 的增加会导致优化效果的下降。综合图4-10(a)(b) 可知, 当 $\alpha = 1$ 时, 算法的效果最好。




图 4-10 (a) 为 F-SA 算法相对 SA 算法的时间效率和 F-S-CLPSO 算法相对 S-CLPSO 算法的时间效率。(b) 为不同 α 值时, F-SA 算法和 F-S-CLPSO 算法优化 λ_c 的结果。

4.2.4 对比分析实验

传输性能实验分别在 10 个 BA 网络和 8 个真实网络中进行。BA 网络中的节点数为 500, 连边数量为 1988, 需要放置主机数目为 100 个, 每个节点的传输性能为 $R = 100$ 。真实网络为从斯坦福网络分析项目 (<http://snap.stanford.edu/>) 获取, 分别从 as-Skitter、as-733、as-Caida 和 Oregon-1 真实网络中抽取 2 个 500 个节点的网络。

表 4-1 传输性能优化结果。时间效率分别为 F-SA 相对于 SA、F-S-CLPSO 相对于 S-CLPSO 的时间效率。每个算法在每个数据上运算 30 次取平均值。节点被选择作为主权重公式

$$w_i = \left(\frac{k_h - k_i}{k_h - k_l} \right)^\alpha \text{ 中 } \alpha = 1。$$

Instance	SA		F-SA		时间效率	S-CLPSO		F-S-CLPSO		时间效率
	λ_c	Time(s)	λ_c	Time(s)		λ_c	Time(s)	λ_c	Time(s)	
BA1	9.90991	19215	9.90991	14922	22.34%	9.90991	18373	9.90991	14404	21.60%
BA2	9.00154	22221	9.01203	17612	20.74%	9.01203	21475	9.01203	16643	22.50%
BA3	10.07981	21809	10.07981	17017	21.97%	10.07981	19811	10.07981	15731	20.59%
BA4	9.78942	19790	9.78942	15792	20.20%	9.78942	17482	9.78942	13934	20.29%
BA5	9.31756	24423	9.31756	19687	19.39%	9.31756	21475	9.31756	16690	22.28%
BA6	9.52138	22375	9.52138	17530	21.65%	9.52138	19012	9.52138	15055	20.81%
BA7	9.92858	24486	9.63782	19669	19.67%	9.92858	21214	9.92858	16769	20.95%
BA8	9.39601	22008	9.39601	16851	23.42%	9.39601	21784	9.39601	17004	21.94%
BA9	9.73510	18468	9.73510	14587	21.01%	9.73510	16331	9.73510	13172	19.34%
BA10	10.00121	24850	10.00121	19934	19.78%	10.00121	21633	10.00121	16778	22.44%
sub-as-Skitter-1	32.89450	31910	32.89450	28971	9.21%	32.89450	30941	32.89450	27583	10.85%
sub-as-Skitter-2	30.19465	30605	30.19465	27859	8.97%	30.19465	29971	30.19465	27210	9.21%
sub-as-733-1	12.72189	22628	12.72189	19023	15.93%	12.72189	19224	12.72189	16417	14.60%
sub-as-733-2	14.21679	20283	14.21679	18009	11.21%	14.21679	19602	14.21679	17465	10.90%
sub-as-Caida-1	13.27550	21326	13.27550	18854	11.59%	13.27550	19815	13.27550	17738	10.48%
sub-as-Caida-2	10.58737	20810	10.58737	18745	9.92%	10.58737	19655	10.58737	17410	11.42%
sub-Oregon-1-1	6.39587	16608	6.39587	14815	10.79%	6.39587	15099	6.39587	13638	9.67%
sub-Oregon-1-2	7.00241	17371	7.01967	15540	10.54%	7.08389	17010	7.08389	15460	9.11%

实验中, SA 和 F-SA 算法的初始温度设定值为 1, 温度下降公式为 $T = 0.99992T$, 优化目标 λ_c 在迭代 1000 次不变时, 算法停止。S-CLPSO 和 F-S-CLPSO 算法中, 种群设定为 30 个, $w = 1, \Delta w = 0.001, c = 4, w$ 值降到 0.4 时保持不变,

$Pc_i = 0.05 + 0.45 * \frac{e^{\frac{10(i-1)}{M-1}-1}}{e^{(10)}-1}$, 优化目标 λ_c 在迭代 300 次保持不变时, 算法停止。

根据 4.2.3 对权重机制参数 α 的分析, 在实验中设置 $\alpha = 1$ 。

实验结果如表 4-1 所示。从实验结果看出, 我们设计的基于解特征的启发式算法在基本不影响优化结果的情况下能够较大的提升算法的时间效率。对 BA 网络的实验中, F-SA 算法相对于 SA 算法的时间效率平均提高了 21.02%, F-S-CLPSO 算法相对于 S-CLPSO 算法的时间效率平均提高了 21.27%。对真实网络的实验中, F-SA 算法相对于 SA 算法的时间效率平均提高了 10.94%, F-S-CLPSO 算法相对于 S-CLPSO 算法的时间效率平均提高了 10.78%。

4.3 复杂通信网络优化

在现实生活中, 我们面对的网络远比我们想象的复杂很多。网络的复杂性主要体现在节点的复杂性和连边的复杂性上。例如在视频服务网络中, 网络节点主要分为三类: 提供视频数据服务的节点、路由器和请求视频服务的节点 (消费节点)。而网络中的连边信息包含链路的带宽和使用费用。网络中用于数据传输的链路中至少有两个管道。两个管道数据的传输方向不同, 但是他们的宽带之和是网络提供商给定的。对于视频服务提供商而言, 如何在网络中布局服务器, 从而以最少的成本给消费者提供视频服务值得深入思考。该问题描述为: 对于给定的 n 个位置, 选取 m 个位置放置视频服务器, 在满足视频服务请求的条件下 (假设所有消费节点的总数据带宽需求为 TBW), 使视频服务提供商的花费最少。数学描述为:

$$\text{minimize} \sum_{i=1}^n \sum_{j=1}^m c_{ij} x_{ij} + \sum_{i=1}^n f_i y_i \quad (4-10)$$

其中

c_{ij} = 消费节点 j 从服务器节点 i 获取数据的花费

f_i = 在网络节点 i 建立服务器的花费

$x_{ij} = \begin{cases} 1; & \text{消费节点 } j \text{ 从服务器 } i \text{ 获取视频服务} \\ 0; & \text{其他} \end{cases}$

$y_i = \begin{cases} 1; & \text{如果在网络节点 } i \text{ 建视频服务器} \\ 0; & \text{其他} \end{cases}$

x_{ij} 是一个二元变量, 对于消费节点 j 可能同时从多个服务器获取数据。 y_i 也是一个二元变量, 当其为 1 时, 表示在网络节点 i 建立服务器。对于该复杂通信模式优化问题, 可以将其分解为两个子问题:

- 1) 位置优化。确定在哪些节点选择建立服务器。
- 2) 视频数据路径规划。数据在网络中怎样传输能使传输费用最少。

4.3.1 位置优化方法

在这里, 我们考虑了如何用离散的粒子群算法进行位置优化。考虑的算法有 S-CLPSO 和带罚金的 S-CLPSO(S-CLPSO-P)。其中 S-CLPSO-P 是来自论文^[57]中 PSO-P 的思想, 我们通过在优化的目标函数中添加罚金函数来处理不满足限制条件的情况。在选择服务器位置时, 最容易想到的方法是在消费节点链接的路由节点上摆放服务器, 也就是说优化后的网络中, 视频服务器数目必然不大于消费节点的数量。所以在初始化粒子时, 可以把该信息考虑进去, 使每个粒子有一个较好的起始状态。

1) S-CLPSO

在 S-CLPSO 中, 如果粒子 i 根据速度信息 V_i 更新的位置 X_i 不满足消费节点的需求时, 我们将从粒子 i 的上一次位置获取信息, 使得更新后的位置能够满足消费节点需求, 否则将从解空间获取位置信息。位置更新的伪代码为算法4.2。粒子的位置信息为含有 m 个元素构成的集合, $x_i = (x_{i1}, x_{i2}, \dots, x_{im})$, 其中 m 为网络中服务器节点数目。初始化时, m 的值设为网络中消费节点的数目, 第一个粒子的位置初始化为消费节点连接的路由器节点, 其他粒子的位置则从网络中随机选择 m 个位置进行初始化, 若选择的位置不能满足消费节点, 则重新选择节点放置服务器。粒子的速度为从网络中随机选择 m 个节点, 并随机赋予一个概率。在算法中 $cut_\alpha(V_i)$ 有两个作用: 1、保留了较好的位置信息用于位置更新。2、能够改变服务器的数目。当 $cut_\alpha(V_i)$ 中的元素不能获得满足限制条件的解时, 采取的措施是不断往 $Candidate_Set_i$ 添加新的位置信息, 直到有满足条件的解, 具体添加方法见算法4.2。

2) S-CLPSO-P

算法 4.2 粒子 i 位置更新伪代码

```

1: procedure POSITION_UPDATING()
2:   generate a random number  $\alpha \in (0, 1)$ ;
3:    $cut_\alpha(V_i) = \{e | (e, p(e)) \in V_i \text{ and } p(e) \geq \alpha\}$ ;
4:    $NEW\_X_i = \{e | e \in cut_\alpha(V_i)\}$ 
5:   if the construction of  $NEW\_X_i$  is not satisfied then
6:      $Candidate\_Set_i = \{e | e \in X_i\}$ ;
7:     while the construction of  $NEW\_X_i$  is not satisfied do
8:       random select element from  $Candidate\_Set_i$  and add to  $NEW\_X_i$ ;
9:     end while
10:  end if
11:   $X_i = NEW\_X_i$ ;
12: end procedure

```

参考文献^[57]中的罚金函数, 我们可以将含有罚金的适应度函数 (fitness function) 定义为:

$$\text{minimize} \sum_{i=1}^n \sum_{j=1}^m c_{ij} x_{ij} + \sum_{i=1}^n f_i y_i + M(NTBW - PTBW) \quad (4-11)$$

其中 M 为罚金权重。NTBW 为消费节点需要的总带宽, PTBW 为所有服务器提供给消费节点的总带宽, PTBW 的值不超过 NTBW。对于添加了罚金的适应度函数, 在算法中不用考虑粒子的位置是否满足条件。对于不满足条件的位置, 通常会有较小的适应度, 该适应度对粒子下次位置的更新是有启发作用的。

4.3.2 视频数据传输路径规划方法

对于视频的数据传输方式, 常采用迪杰斯特拉计算网络的最短路径。我们通过下图来说明这个问题。边的权值 (2, 1) 表示该链路的费用为 2 元/Gbps, 链路总带宽为 1Gbps。图4-11中服务器能提供无限的宽带, 消费节点 1、2 的带宽需求均为 1。我们先来看两种规划方式: 1、先规划服务器 1 到消费节点 1 的路径, 为 1->2->3->4, 花费为 3 元; 最后规划服务器 1 到消费节点 2 的路径, 为 1->3->2->5, 花费为 5 元; 总共花费为 9 元。2、先规划服务器 1 到消费节点 2 的路径, 为 1->2->5, 花费为 2 元; 最后规划服务器 1 到消费节点 2 的路径, 为 1->3->4, 花费为 4 元; 总共花费为 6 元。在这个问题上采用了在残余网络上总是沿着最短路径增广的方计算网络中视频数据传输路径的花费。这种贪心的方

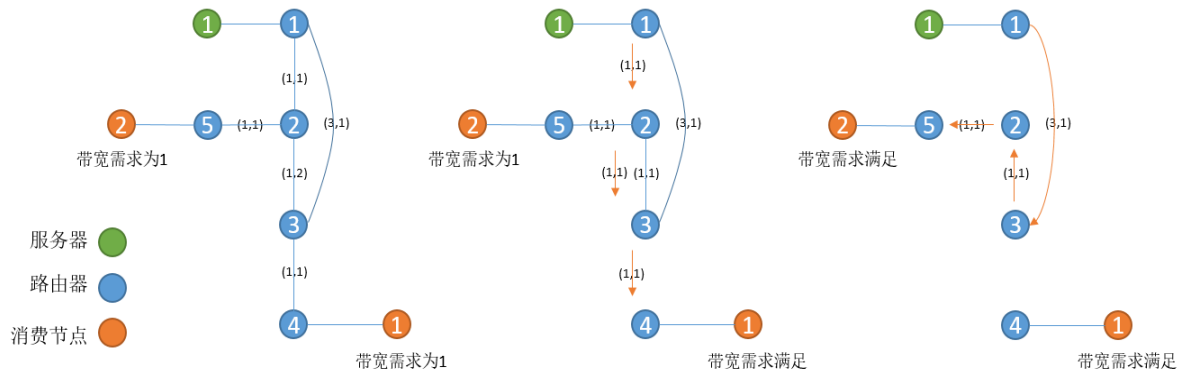


图 4-11 贪心的最小费用流示例。

法不能保证每次找到的路径能使网络中的数据传输费用最小，为了使这个贪心过程可逆，应该在残余网络中添加反向边来保证过程的可逆，残余网络中的方向边的费用为原边的相反数。由于原生 Dijkstra 算法只适用非负权边的网络，所以我们只能用改进后的 Dijkstra 或者 Bellmax-Ford 算法。图4-12展示了搜索最优路径的方法。当寻找从路由器 1 到路由器 4 的最短路径时，搜索到的最短路径为

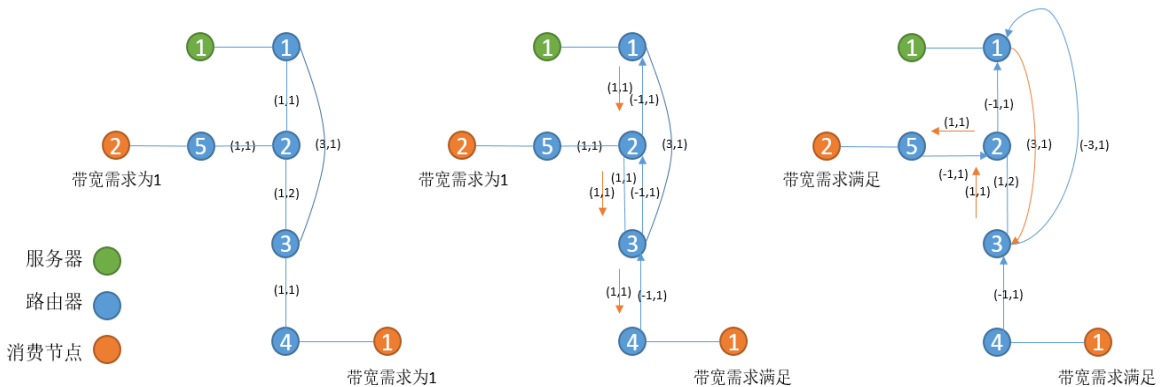


图 4-12 基于添加负权反向边的最小费用流示例。

1->2->3->4，计算该路径的使用宽带为 1Gbps。当链路带宽被使用时，在相应链路的反方向添加相应的反向边，若反向边存在则不用添加。反向边的租用费用为原方向的相反数。反向边允许的带宽相应增加，增加额为原方向带宽的需求量。因此在残余网络中添加反向边 4->3->2->1，添加相应的边权重 $(-1,1), (-1,1), (-1,1)$ 。不断在残余网络上进行上述过程。最后可以得到网络最理想的流量分布：1->2 使用了 1Gbps 的带宽，2->5 使用了 1Gbps 的带宽，1->3 使用了 1Gbps 的带宽，3->4 使用了 1Gbps 的带宽。最后真实网络中视频流量路径，只需沿着负权边反

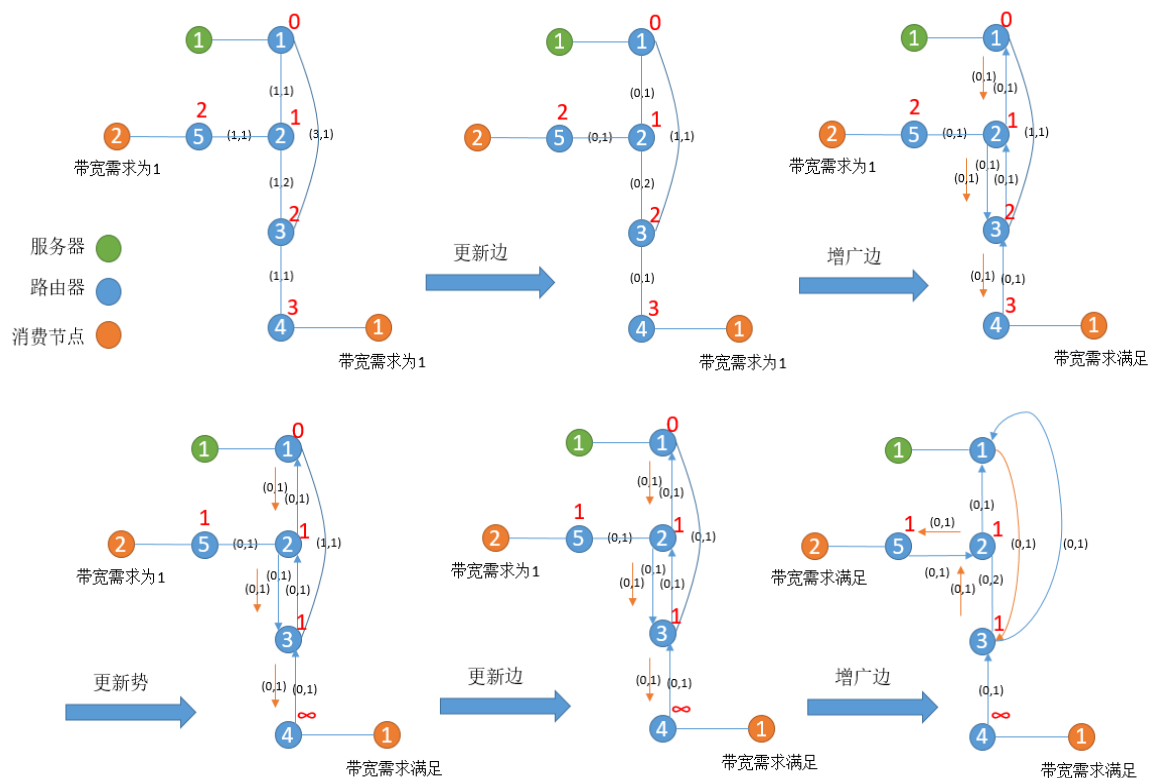


图 4-13 基于势更新边的最小费用流示例

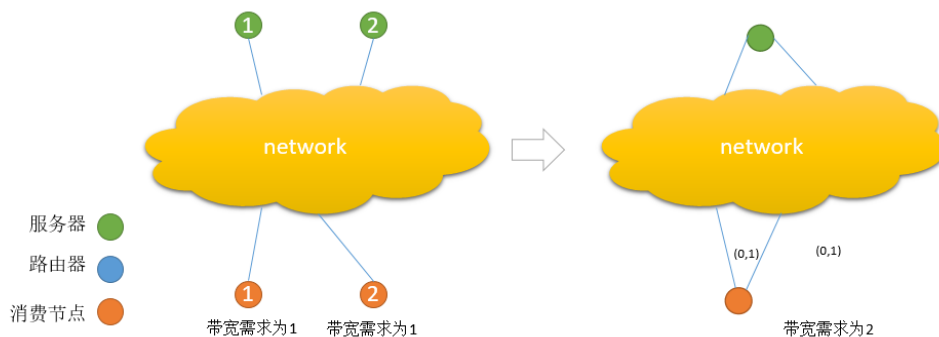


图 4-14 将消费节点和服务节点分别合并为超级服务器节点和超级消费节点。

方向遍历。需要注意的是在最小费用流中一定不存在回路，即不存在负圈。对于给定的流 f ，如果在同样带宽需求，存在费用比 f 小的流 f_1 。在流中，路由器节点的数据流入和数据流出的流量相等，流 $f - f_1$ 的所有路由器的流入流量等于流出流量，即为若干的圈组成。由于 $f - f_1$ 的费用是负的，所以在这些圈中，至少存在一个负圈。也就是说 f 是最小费用流和网络中不存在负圈相互等价。若采用执行 F 次的 Bellmax-Ford，该算法的复杂度为 $O(F|V||E|)$ 。如果用改进后

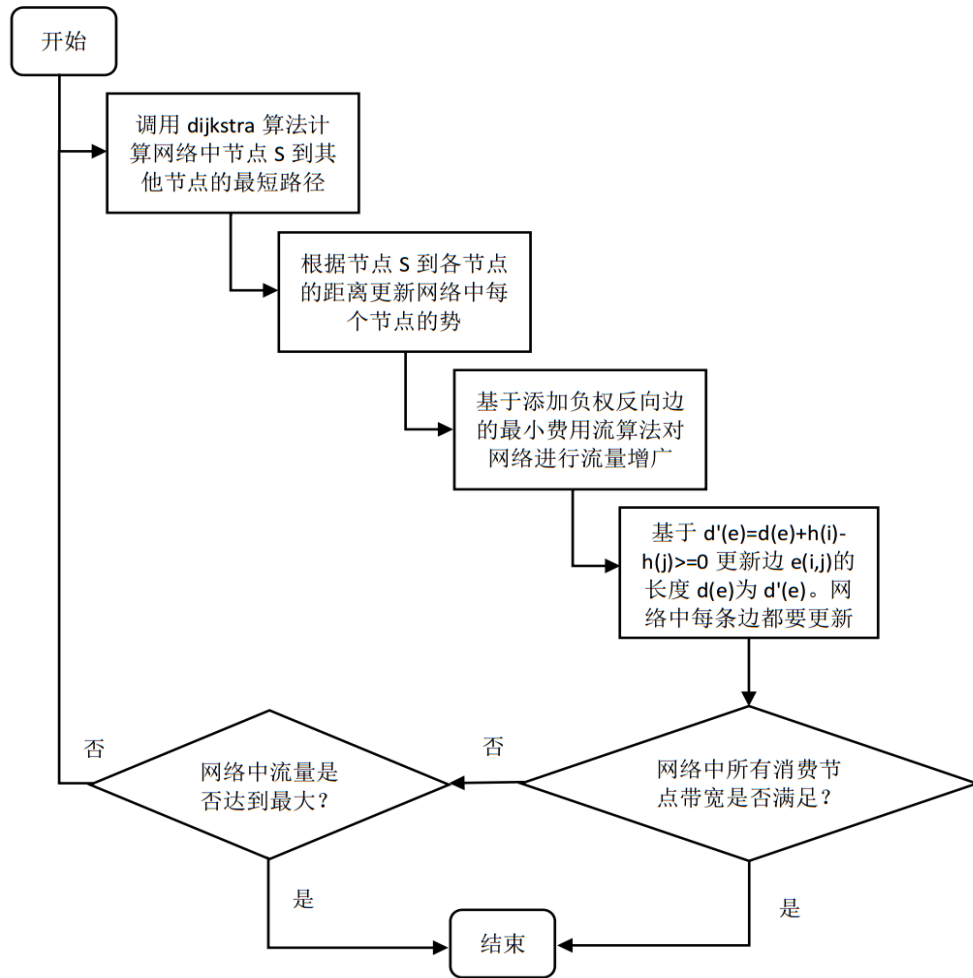


图 4-15 基于势的最小费用流算法流程图。在论文的实验场景中，S 为超级服务器节点。

的 Dijkstra 算法，复杂度为 $O(F|V|^2)$ 。我们在原始 Dijkstra 算法中引入势概念，对于节点 i ，其势为 $h(i)$ ，我们将边 $e(i, j)$ 的长度修正为 $d(e) + h(i) - h(j)$ 。只要能选取合适的势使得修正后的每条边的路径长度为正，那么就可以用 Dijkstra 算法。对于网络中节点 s 和边 $e(i, j)$ 有：(s 到 j 的最短距离) \leq (s 到 i 的最短距离) + 边 $e(i, j)$ 的长度 $d(e)$ ，于是有： $d'(e) = d(e) + h(i) - h(j) \geq 0$

所以我们可以选择服务器连接的路由节点到网络中其他节点的最短距离作为相应节点的势。如图4-13，在开始时，由于网络中不存在负权边，可直接用 Dijkstra 来计算网络中路由器 1 到其他节点的最短距离，并更新各节点的势，更新势后对网络视频数据流路径进行增广，对增广后的残余网络将 d' 带入 Dijkstra 计算路由器 1 到其他节点的最短距离，重新更新势，更新势后继续对视频数据流路径进行增广，直到满足消费节点的带宽需求。

采用势的方法更新边的距离为非负数，从而可以使用 Dijkstra 算法，该方法

只适用于网络中个有单个视频服务器的网络，为了使该方法具有普适性，可以把所有视频服务器合并为一个超级视频服务器，消费节点合并为超级消费节点(也可以不合并)，如图4-14所示。基于势的最小费用流算法流程图如图4-15所示。

4.3.3 实验结果

表 4-2 不同算法情况下的花费。每个数据进行实验 30 次取平均值，花费单位为元。

Instance	贪心最小费用流		基于添加反向负权边的最小费用流		已知最小花费
	S-CLPSO	S-CLPSO-P	S-CLPSO	S-CLPSO-P	
smallcase0	23101	23056	22554	22256	22256
smallcase1	22918	22601	22217	22009	22009
smallcase2	22041	22000	21654	21469	21469
smallcase3	23949	23552	23243	23254	23103
smallcase4	22989	22366	22289	22159	22159
smallcase5	22006	21644	21706	21574	21500
smallcase6	22920	22837	22777	22717	22717
smallcase7	23012	23012	22811	22473	22473
smallcase8	22299	22332	22150	22217	22150
mediumcase0	42717	42801	42546	42270	42270
mediumcase1	41103	41009	40968	40701	40681
mediumcase2	41987	41111	41617	40802	40802
mediumcase3	42981	42663	42555	42267	42267
mediumcase4	41975	41443	41603	41141	41141
mediumcase5	42826	42798	42732	42622	42622
mediumcase6	43179	42889	43041	42786	42786
mediumcase7	40075	39810	39167	39242	39111
mediumcase8	43844	43590	43512	43351	43351
bigcase0	105107	104910	106025	104714	104714
bigcase1	109097	108123	108973	107811	107811
bigcase2	109997	110036	109621	109332	109332
bigcase3	107912	107541	107148	107099	107099
bigcase4	110993	110710	110328	110430	110328
bigcase5	111400	110058	109135	109407	109110
bigcase6	111099	110938	110661	111153	110599
bigcase7	112438	111280	111565	111116	111116
bigcase8	111103	111092	110824	111044	111044

实验数据来自于 2017 华为软件精英挑战赛，数据分别分为小、中、大网络。数据集可从<https://github.com/zengjunwen/2017codecraft>下载。实验结果

如表4-2所示。实验中 S-CLPSO-P 能计算出不错的结果，但是需要调节参数 M 。如果罚金权重太高，S-CLPSO-P 容易陷入局部最优解。如果太小，粒子很难搜索到可行的解 (服务器的位置不满足消费节点的带宽请求)。

4.4 结束语

本章采用了模拟退火和粒子群优化算法对网络进行优化。详细分析了优化后的网络具有的特点。优化传输性能后的网络特点：1、网络的主机既有大度节点也有小度节点，但没有选择度很大的节点。2、优化后主机到主机的平均最短路径比网络的平均路径长，基本与只选小度节点为主机时的主机到主机平均最短距离一样。3、网络中的负载很均匀的分布在网络中。优化后的网络鲁棒性特点：1、网络的主机既有大度节点也有小度节点，但没有选择度很大的节点。2、优化后主机到主机的平均最短路径长度没有太明显的特性。对于优化后的鲁棒性的值，有多种主机放置方法，相对应的主机到主机的平均最短路径长度在网络平均最短路径长度附近波动。3、优化后的负载并没有像优化网络传输性能那样使得网络中的负载均匀分布在网络中，其负载分布 $U(i)$ 的表现比较接近 LDTA 模式下的 $U(i)$ 表现。除此之外，在论文中还实验中的代码优化问题进行了概括性的描述，分析了如何对最短路径算法进行优化。

在对网络的传输性能进行优化后，针对优化后网络的特点，提出了基于解特征的 SA 算法和 S-CLPSO 算法，在算法中引入了节点被选为主机的权重机制。这两种算法在对 BA 网络和真实网络的传输性能优化时相对于传统方法能够在保存优化结果不变的情况下提高算法的运行速度。

在最后一小节中，我们考虑了现实中遇到的复杂通信网络模型：1、网络中含有服务节点、消费节点和路由节点。2、传输数据的连边有传输速度限制，并要为使用的路径付费。3、安装服务器需要花钱。针对这种复杂的通信模式，我们需要解决的是在满足各个消费节点需求的情况下，合理放置服务器，使得需要花费的现金最少。为了解决该问题，论文从位置优化和数据传输路径规划两方面着手：1、针对位置优化，设计了基于集合的综合学习粒子群优化算法和罚金 + 基于集合的综合学习粒子群优化算法。在算法中给出了比较好的初始粒子位置 (粒子位置包括两个信息：服务器数目和服务器位置)。2、针对数据传输路径规划方法，在增广数据传输路径的过程中，通过添加反向负权边的方法来

解决传输费用最小的最优化问题。除此之外，设计了基于势的 Dijkstra 算法用于计算含有负权边的最短路径。

第五章 总结与展望

5.1 总结

全文的工作主要围绕通信模式对网络的影响展开，针对通信模式主要考虑了网络中放置主机的方法，除此之外，还对网络性能进行优化设计。在第一章主要介绍了复杂网络的研究背景、研究现状和本文的研究工作。在第二章中概述了复杂网络模型如何建模。论文从实证数据出发，分析了现实网络背后存在的增长和偏好依附机制。本章在阐述通信系统传输机理和级联失效模型后，详细分析了衡量网络性能的两个指标：传输性能和鲁棒性。为后续实验做好理论铺垫。除此之外，还对优化算法进行理论描述，并从控制理论角度进行调优参数分析。第三章在 ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络中，对 HDTA、LDTA、BTA 和 RA 四种模式进行实验，并对实验结果进行详细的分析。第四章为优化实验，对比的优化算法有贪心算法、模拟退火算法和基于集合的综合学习粒子群优化算法。在第四章的最后，针对复杂通信网络设计了带罚金的基于集合的综合学习粒子群算法 (S-CLPSO-P)，实验得到不错的优化结果。该论文研究成果总结主要如下：

- 1) ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络的传输性能：当网络中每个节点的传输能力一样时，HDTA、LDTA、BTA 和 RA 对网络传输性能的影响不存在明显差异，差异稍微明显的情况是在主机比例小于 0.3 的情况下。在传输效益方面，HDTA 和 BTA 表现甚好，甚至有基本一致的情况。
- 2) ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络在蓄意攻击时网络的鲁棒性：ER 随机网络在 LDTA 模式下的鲁棒性总体而言会好一些，BA 无标度网络在 HDTA 模式下的鲁棒性总体而言要好一些，含社区的 BA 无标度网络在 HDTA 模式下的鲁棒性总体而言要好很多。
- 3) ER 随机网络、BA 无标度网络和含有社区的 BA 无标度网络在随机失效时网络的鲁棒性：三种网络中，在 HDTA 模式下的鲁棒性是最好的，但在 ER

随机网络中 LDTA、BTA 和 RA 模式下的鲁棒性与 HDTA 模式下差别不是太大。

- 4) 在 BA 无标度网络中, 优化传输性能后的网络特点: 1、网络的主机既有大度节点也有小度节点, 但没有选择度很大的节点; 2、优化后的主机到主机的平均最短路径比较网络的平均路径长, 基本与只选小度节点为主机时的主机到主机平均最短距离一样; 3、网络中的负载很均匀的分布在网络中。
- 5) 针对复杂网络领域网络性能的优化问题, 首次将离散的粒子群算法应用到该问题中, 论文中对算法的设计进行了详细描述。
- 6) 针对优化实验中, 对网络传输性能优化后的网络特点, 我们设计了基于解特征的 SA 算法和 S-CLPSO 算法, 该算法的主要思想为在算法中引入了节点被选择为主机节点的权重机制。通过实验分析权重调节参数 α , 该参数能够对算法的优化效果和算法速度造成影响。合理设置权重调节参数, 能够使得改进后的算法在保证优化结果不变的情况下提高算法对 BA 网络和真实网络传输性能的优化速度。
- 7) 针对复杂通信网优化问题, 我们设计了基于罚金的 S-CLPSO 算法进行主机服务器选址。对于数据传输路径规划, 我们对贪心的最小流费用算法和基于负权反向边的最小费用算法进行了实验对比。大量的最短路径算法研究表明 Dijkstra 算法相对于 SPAF 算法, 具有很高的稳定性。因此我们设计了基于势的 Dijkstra 算法解决数据路径规划中含有负权边的最短路径的计算问题。除此之外, 由于 Dijkstra 算法是单源最短路径算法, 所以将服务器节点合并为一个超级节点能够大大的降低算法复杂度。

5.2 展望

本研究课题的展望主要在以下几个方面:

- 1) 对于级联失效过程, 该实验中采取了不考虑时间因素的失效模型, 为了能够得到更符合实际的级联失效模型, 考虑时间因素尤为重要, 因此未来将对带有时间因素的积分失效模型进行研究。

- 2) 对于复杂网络的优化研究不应该只停留在文章中提到的几种优化算法上，针对离散问题的蚁群算法值得在复杂网络优化中进行研究。
- 3) 随着科技的发展，网络虚拟化的概念提出来很久，如何将复杂网络理论知识和虚拟化网络架构设计结合起来值得深入研究。特别是在网络资源的调度方面，如何根据网络的历史信息预测未来的网络需求变化，从而实现网络资源的合理分配。

参考文献

- [1] Watts D, Strogatz S. Collective dynamics of 'small-world' networks [J]. Nature, 1998, 393 (6684): 440—442.
- [2] Barabási A-L, Albert R. Emergence of scaling in random networks [J]. Science, 1999, 286: 509–512.
- [3] Council N R. Committee on Network Science for Future Army Applications [M]. National Academies Press, 2006.
- [4] 汪小帆, 李翔, 陈关荣. 网络科学导论 [M]. 高等教育出版社, 2012.
- [5] Newman M. Network: An Introduction [M]. Oxford University Press, 2010.
- [6] Lewis T. Network Science: Theory and Applications [M]. John Wiley and Sons, 2011.
- [7] Al-Sultan K S, Al-Fawzan M A. A tabu search approach to the uncapacitated facility location problem [J]. Annals of Operations Research, 1999, 86: 91–103.
- [8] Gendreau M, Iori M, Laporte G, *et al.* A tabu search heuristic for the vehicle routing problem with two-dimensional loading constraints [J]. Networks, 2008, 51 (2): 153.
- [9] Arrowsmith D, Bernardo M, Sorrentino F. Effects of variations of load distribution on network performance [J], 2005: 4–9.
- [10] Echenique P, Gómez-Gardeñes J, Moreno Y. Improved routing strategies for Internet traffic delivery [J]. Physical Review E, 2004, 70 (52): 1–5.
- [11] Zhang G-q, Wang D, Li G-j. Enhancing the transmission efficiency by edge deletion in scale-free networks [J], 2007: 1–4.
- [12] Huang W, Chow T W S. Effective strategy of adding nodes and links for maximizing the traffic capacity of scale-free network [J]. Chaos, 2010, 20 (3): 033123.
- [13] Tan F, Xia Y. Hybrid routing on scale-free networks [J]. Physica A Statistical Mechanics and its Applications, 2013, 392: 4146–4153.

- [14] Wu J, Tse C K, Lau F C M. Optimizing Performance of Communication Networks: An Application of Network Science [J]. IEEE Transactions on Circuits and Systems II: Express Briefs, 2015, 62 (1): 95–99.
- [15] Wang J, Rong L, Zhang L, *et al.* Attack vulnerability of scale-free networks due to cascading failures [J]. Physica A: Statistical Mechanics and its Applications, 2008, 387: 6671–6678.
- [16] Motter A E, Lai Y-C. Cascade-based attacks on complex networks [J]. Physical Review E, 2002, 66: 065102.
- [17] Motter A E. Cascade control and defense in complex networks [J]. Physical Review Letters, 2004, 93: 098701.
- [18] Jiang Z-Y, Ma J-F, Shen Y-L, *et al.* Effects of link-orientation methods on robustness against cascading failures in complex networks [J]. Physica A: Statistical Mechanics and its Applications, 2016, 457: 1–7.
- [19] Jiang Z-Y, Ma J-F. An efficient local cascade defense method in complex networks [J]. International Journal of Modern Physics C, 2017, 28: 1750031.
- [20] Zhang X, Zhan C, Tse C K. Modeling the Dynamics of Cascading Failures in Power Systems [J], 2017, 7 (2): 192–204.
- [21] Crucitti P, Latora V, Marchiori M. Model for cascading failures in complex networks [J]. Physical Review E, 2004, 69: 045104.
- [22] Xia Y, Fan J, Hill D. Cascading failure in Watts-Strogatz small-world networks [J]. Physica A: Statistical Mechanics and its Applications, 2010, 389: 1281–1285.
- [23] Wang J-W, Rong L-L. Cascade-based attack vulnerability on the US power grid [J]. Safety Science, 2009, 47: 1332–1336.
- [24] P Erdős A R. On the evolution of random graphs [J]. Publ. Math. Inst. Hungar. Acad. Sci., 1960, 5: 343–347.
- [25] Zhao L, Park K, Lai Y-C, *et al.* Tolerance of scale-free networks against attack-induced cascades [J]. Physical Review E, 2005, 72: 025104.

- [26] Wu J, Gao Z, Sun H. Effects of the cascading failures on scale-free traffic networks [J]. *Physica A: Statistical Mechanics and its Applications*, 2007, 378: 505–511.
- [27] Cao X-B, Hong C, Du W-B, *et al.* Improving the network robustness against cascading failures by adding links [J]. *Chaos, Solitons and Fractals*, 2013, 57: 35–40.
- [28] Yang R, Wang W-X, Lai Y-C, *et al.* Optimal weighting scheme for suppressing cascades and traffic congestion in complex networks [J]. *Physical Review E*, 2009, 79: 026112.
- [29] Wang J. Mitigation strategies on scale-free networks against cascading failures [J]. *Physica A: Statistical Mechanics and its Applications*, 2013, 392: 2257–2264.
- [30] Wang J. Robustness of complex networks with the local protection strategy against cascading failures [J]. *Safety Science*, 2013, 53: 219–225.
- [31] Qiu Y. Cascading dynamics with local weighted flow redistribution in interdependent networks [J]. *European Physical Journal B*, 2013, 86: 329–337.
- [32] Nie S, Wang X, Zhang H, *et al.* Robustness of controllability for networks based on edge-attack [J]. *Plos One*, 2014, 9 (2): e89066.
- [33] Xia Y, Zhang W, Zhang X. The effect of capacity redundancy disparity on the robustness of interconnected networks [J]. *Physica A: Statistical Mechanics and its Applications*, 2016, 447: 561–568.
- [34] Chen Z, Wu J, Xia Y, *et al.* Robustness of interdependent power grids and communication networks: a complex network perspective [J]. *IEEE Transactions on Circuits and Systems II: Express Briefs*, 2017, 65: 115–119.
- [35] Du W-B, Zhou X-L, Lordan O, *et al.* Analysis of the Chinese Airline Network as multi-layer networks [J]. *Transportation Research Part E: Logistics and Transportation Review*, 2016, 89: 108–116.
- [36] Tan F, Xia Y, Wei Z. Robust-yet-fragile nature of interdependent networks [J]. *Physical Review E*, 2015, 91: 052809.
- [37] Brandes U. A faster algorithm for betweenness centrality [J]. *The Journal of Mathematical Sociology*, 2001, 25 (2): 163–177.

- [38] Newman M. Assortative mixing in networks [J]. *Physical Review Letters*, 2002, 89 (20): 2087011–1087014.
- [39] Eom Y H, Fortunato S. Characterizing and modeling citation dynamics [J]. *PLoS ONE*, 2011, 6 (9): 1–7.
- [40] Li C, Maini P K. An evolving network model with community structure [J]. *Journal of Physics A: Mathematical and General*, 2005, 38 (45): 9741–9749.
- [41] Wu J, Tse C K, Lau F C M. Concept of Node Usage Probability From Complex Networks and Its Applications to Communication Network Design [J]. *IEEE Transactions on Circuits and Systems I: Regular Papers*, 2015, 62 (4): 1195–1204.
- [42] Brummitt C D, D’Souza R M, Leicht E A. Suppressing cascades of load in interdependent networks [J]. *Proceedings of the National Academy of Sciences of USA*, 2012, 109: E680–E689.
- [43] Kirkpatrick S V M, Gelatt CD. Optimization by Simulated Annealing [J], 1983, 220 (4598): 671–680.
- [44] Eberhart R, Kennedy J. A new optimizer using particle swarm theory [C]. In *Proceedings of the Sixth International Symposium on Micro Machine and Human Science*, 1995: 39–43.
- [45] Shi Y, Eberhart R. A modified particle swarm optimizer [C]. In *1998 IEEE International Conference on Evolutionary Computation Proceedings*, 1998.
- [46] Shi Y, Eberhart R C. Fuzzy adaptive particle swarm optimization [C]. In *Proceedings of the 2001 Congress on Evolutionary Computation*, 2001: 101–106.
- [47] Clerc M, Kennedy J. The particle swarm - explosion, stability, and convergence in a multidimensional complex space [J]. *IEEE Transactions on Evolutionary Computation*, 2002, 6 (1): 58–73.
- [48] van den Bergh F, Engelbrecht A P. A Cooperative approach to particle swarm optimization [J]. *IEEE Transactions on Evolutionary Computation*, 2004, 8 (3): 225–239.
- [49] Sha D, Hsu C-Y. A hybrid particle swarm optimization for job shop scheduling problem [J]. *Computers and Industrial Engineering*, 2006, 51 (4): 791–808.

- [50] Afshinmanesh F, Marandi A, Rahimi-Kian A. A Novel Binary Particle Swarm Optimization Method Using Artificial Immune System [C]. In EUROCON 2005 - The International Conference on "Computer as a Tool", 2005: 217–220.
- [51] Liang J J, Qin A K, Suganthan P N, *et al.* Comprehensive learning particle swarm optimizer for global optimization of multimodal functions [J]. IEEE Transactions on Evolutionary Computation, 2006, 10 (3): 218–295.
- [52] Chen W-n, Member S, Zhang J, *et al.* A Novel Set-Based Particle Swarm Optimization Method for Discrete Optimization Problems [J]. IEEE Transactions on Evolutionary Computation, 2010, 14 (2): 278–300.
- [53] Kennedy J. Small worlds and mega-minds: Effects of neighborhood topology on particle swarm performance [M]. 1999.
- [54] Kennedy J, Mendes R. Population structure and particle swarm performance [C]. In Proceedings of the 2002 Congress on Evolutionary Computation, 2002: 1671–1676.
- [55] Blackwell T, Bentley P. Don't push me! Collision-avoiding swarms [J], 2002, 2: 1691 – 1696.
- [56] Kennedy J, Eberhart R C. A discrete binary version of the particle swarm algorithm, 1997: 4104–4108.
- [57] Kong M, Tian P. Apply the Particle Swarm Optimization to the Multidimensional Knapsack Problem [J], 2006 (2): 1140–1149.

攻读学位期间发表的学术论文和研究成果

- 1) EI 国际会议论文 “Effect of traffic generation patterns on traffic performance of complex networks”, 2016APCCAS, 韩国济州岛, 已收录 (与学位论文第 3 章相关, 本人为第一作者);
- 2) SCI 期刊论文: ”Effects of traffic generation patterns on the robustness of complex networks”, Physica A: Statistical Mechanics and its Applications, 已收录 (与学位论文第 3 章相关, 导师为第一作者, 本人为第二作者);
- 3) 专利: 一种基于复杂通信网络的主机位置选择方法, 已公开 (与学位论文第 5 章相关, 导师为第一作者, 本人为第二作者)。